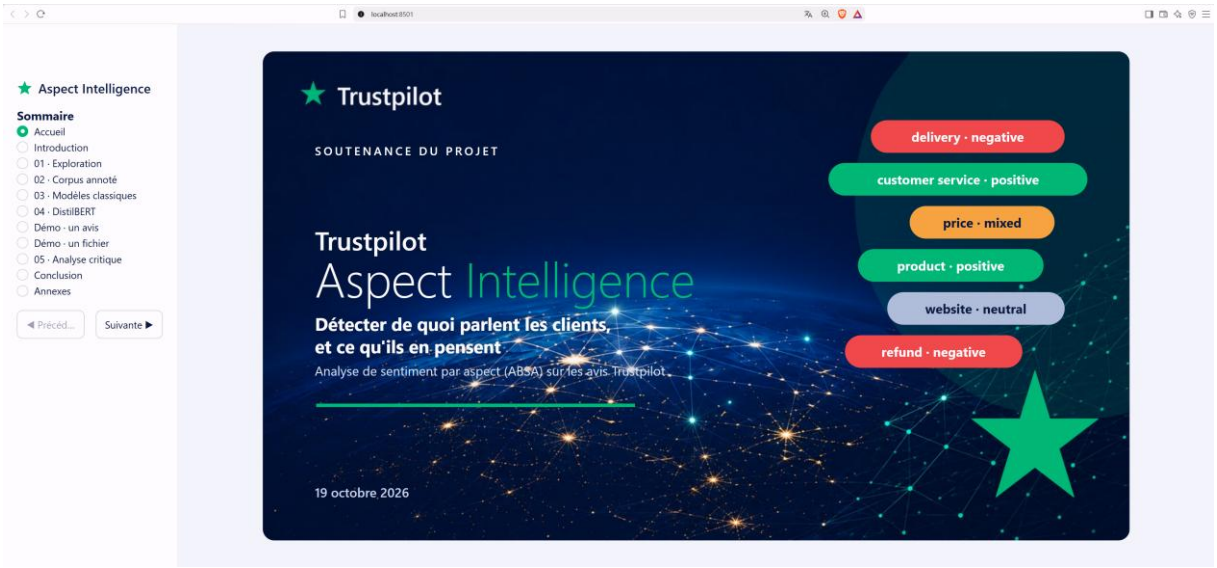
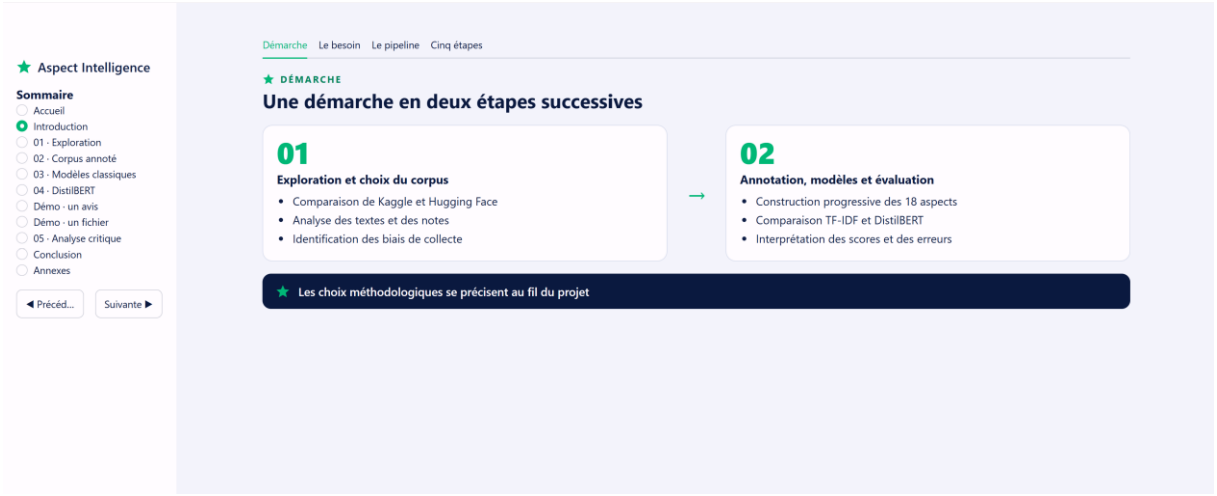

Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
Trustpilot
SOUTENANCE DU PROJET
Trustpilot
Aspect Intelligence
Détecter de quoi parlent les clients, et ce qu'ils en pensent
Analyse de sentiment par aspect (ABSA) sur les avis Trustpilot
19 octobre 2026
delivery · negative
customer service · positive
price · mixed
product · positive
website · neutral
refund · negative


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
Démarche
Le besoin
Le pipeline
Cinq étapes
DÉMARCHE
Une démarche en deux étapes successives
01
Exploration et choix du corpus
Comparaison de Kaggle et Hugging Face
Analyse des textes et des notes
Identification des biais de collecte
→
02
Annotation, modèles et évaluation
Construction progressive des 18 aspects
Comparaison TF-IDF et DistilBERT
Interprétation des scores et des erreurs
Les choix méthodologiques se précisent au fil du projet


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
Démarche
Le besoin
Le pipeline
Cinq étapes
LE BESOIN
Une note sur 5 résume l'expérience, sans dire ce qu'il faut améliorer
Un même avis, deux sujets, deux appréciations
« The delivery was very late, but the customer service was excellent and very helpful. »
La note globale donne une seule valeur, de 1★ à 5★, pour tout l'avis
Ce que l'entreprise veut savoir
delivery · negative
customer service · positive
Repérer les irritants
Suivre les thèmes négatifs qui reviennent
Comparer les secteurs
Lire les aspects selon la catégorie d'activité
Prioriser les actions
Moins de lecture manuelle, plus de décisions
Objectif : retrouver chaque aspect exprimé dans un avis et lui associer son propre sentiment

★ NOTRE APPROCHE

Le pipeline d'analyse : deux modèles enchaînés

Avis client (texte libre) → **Modèle 1** (détection des aspects) → **Aspects détectés** (0 à n parmi 18) → **Modèle 2** (sentiment par aspect) → **Sortie** (couples aspect–sentiment)

Tâche 1 · détection des aspects
- Classification multi-label : plusieurs aspects par avis
- 18 aspects métier, de product à accessibility
- Métriques : Micro-F1 et Macro-F1

Tâche 2 · sentiment par aspect
- Classification multiclasse : un sentiment par couple
- Entrée : nom de l'aspect + texte de l'avis
- Métriques : Accuracy, Macro-F1 et Weighted-F1

★ **Critère principal : le Macro-F1, qui donne le même poids à chaque aspect et à chaque sentiment, même rare**

★ DÉMARCHE

Cinq étapes, de l'exploration des avis au modèle retenu

01	02	03	04	05
Explorer	**Annoter**	**Modèles classiques**	**DistilBERT**	**Analyse critique**
Comparer deux corpus publics, repérer les biais de collecte	Échantillonner, construire l'ontologie, annoter GOLD et SILVER	TF-IDF avec régression logistique, SVM et XGBoost	Fine-tuning de deux modèles, un par tâche, sur CPU	Usage métier, limites et suites du projet
123 181 avis	18 aspects	0,524 Macro-F1	0,585 Macro-F1	7 limites

★ **En annexe : scores des six configurations, détail des 18 aspects et sources du projet**



Deux corpus publics comparés : Hugging Face apporte volume et diversité

	Kaggle	Hugging Face
Avis	3 698	123 181
Entreprises	214	1 680
Catégories	non structurées	22
Longueur médiane	159 caractères	290 caractères
Avis par entreprise (max)	20	100
Dates des avis	oui	non
Valeurs manquantes	686 (description)	aucune

33,3 fois
plus d'avis dans Hugging Face que dans Kaggle

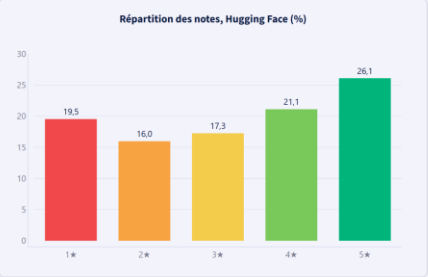
7
avis communs seulement : les deux corpus sont distincts

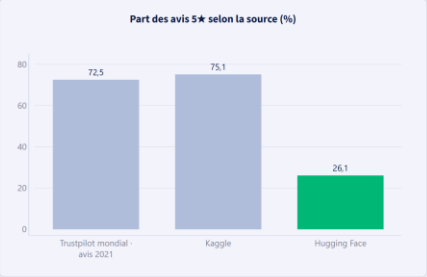
Trustpilot UK
source de Hugging Face, avis majoritairement en anglais

Seulement 7 avis communs. Kaggle sert à la comparaison exploratoire. L'évaluation externe des modèles reste à réaliser.

★ Hugging Face devient le corpus principal ; Kaggle reste un corpus de contrôle (dates, distribution des notes)

Un plafond de 20 avis par note et par entreprise rééquilibre les notes





Une entreprise à 20 avis par note :
(20×1 + 20×2 + 20×3 + 20×4 + 20×5) / 100 = 3

558
entreprises avec exactement 20 avis par note

611
entreprises à moyenne exactement égale à 3

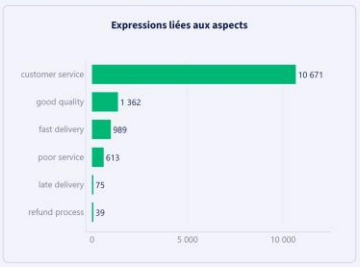
χ^2 = 4 559,54
p ≈ 0 : distributions Kaggle et HF différentes

★ Un bon corpus pour apprendre le langage des avis, pas pour mesurer la satisfaction réelle

Le vocabulaire des avis est riche, mais le sens dépend du contexte

Rang des mots métier parmi 73 755 formes

service	6e
delivery	12e
order	17e
customer	26e
quality	79e
price	81e

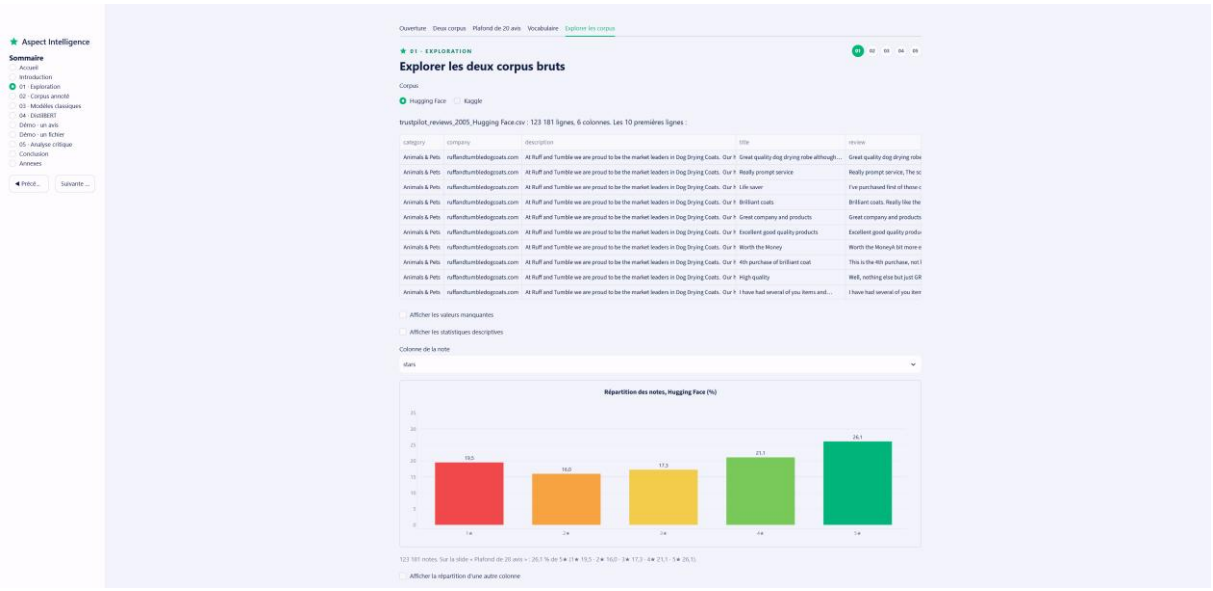


Le piège des négations

« not good »	775
« not great »	474
« not easy »	197
« not helpful »	189

Compter « good » comme positif sans lire la phrase conduirait à des erreurs.

★ Un comptage de mots ne suffit pas : il faut un modèle qui lit le contexte


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
Ouverture
Deux corpus
Plafond de 20 avis
Vocabulaire
Explorer les corpus
01 - EXPLORATION
Explorer les deux corpus bruts
Corpus
Hugging Face
Kaggle
Répartition des notes, Hugging Face (%)


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
Ouverture
Échantillon
Ontologie
Règles d'annotation
GOLD et SILVER
Déséquilibre
Explorer les données
02
Corpus annoté
Échantillonner, construire l'ontologie, annoter GOLD et SILVER

★ 02 · CORPUS ANNOTÉ

2 000 avis stratifiés par catégorie et par note, fidèles au corpus retenu

123 181 avis
corpus Hugging Face

↓

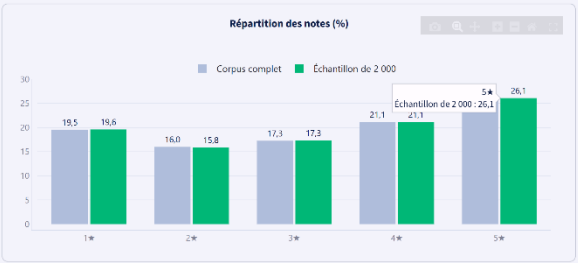
2 000 avis
strates catégorie × note (110 strates)

↓ ↓

600 avis
corpus pilote → GOLD

1 400 avis
reste → SILVER

Richesse lexicale (faible / moyenne / forte) : pilote 40,5 / 33,3 / 26,2 %, échantillon 39,6 / 33,8 / 26,6 %



0,13 pt
écart maximal sur la part d'une note

0,08 pt
écart maximal sur une catégorie

281 / 290
caractères, longueur médiane

19 / 20
mots les plus fréquents communs

★ Fidèle au corpus retenu, l'échantillon hérite aussi de son plafond de 20 avis par note et par entreprise

★ Aspect Intelligence

Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes

◀ Précéd... Suivante ▶

Ouverture Échantillon Ontologie Règles d'annotation GOLD et SILVER Déséquilibre Explorer les données

01 02 03 04 05

★ 02 · ONTOLOGIE

Une ontologie de 18 aspects construite sur les 600 avis pilotes

Construction progressive

1. Lecture libre des avis pilotes
2. Regroupement des formulations proches
3. Test des catégories sur d'autres avis
4. Fusion, séparation ou ajout
5. **Ontologie stabilisée : 18 aspects**

18 aspects

accessibility	app	booking
cleanliness	communication	customer service
delivery	environment	packaging
payment	price	product
refund	replacement	return
staff	trustworthiness	website

Une ligne par avis et par aspect · mentions regroupées · étoiles masquées (GOLD)

4 sentiments, par aspect

- positive — appréciation favorable
- negative — appréciation défavorable
- neutral — aspect mentionné, sans appréciation
- mixed — favorable et défavorable sur le même aspect

★ Deux aspects aux sentiments opposés ne font pas un mixed : chacun reçoit son propre sentiment

★ Aspect Intelligence

Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes

◀ Précéd... Suivante ▶

Ouverture Échantillon Ontologie Règles d'annotation GOLD et SILVER Déséquilibre Explorer les données

01 02 03 04 05

★ 02 · RÈGLES D'ANNOTATION

Des aspects proches, des objets évalués différents

Le sujet évalué guide l'aspect. Les mots employés ne suffisent pas à trancher.

	Aspect	Ce qui est évalué	Exemple illustratif
	staff	Attitude, compétence ou comportement du personnel	*Un vendeur patient et aimable.*
	customer service	Prise en charge d'une demande ou résolution d'un problème	*Mon problème a été réglé rapidement.*
	communication	Information transmise, clarté des échanges et suivi	*Les mises à jour étaient claires et régulières.*

Un avis peut réunir plusieurs aspects, chacun avec son propre sentiment.

Les annotations comportent encore des chevauchements. Certains cas ambigus restent à harmoniser.

★ Le corpus GOLD constitue une référence vérifiée, avec des conventions et des limites explicites

★ 02 · ANNOTATION

GOLD et SILVER : un découpage commun au niveau de l'avis

GOLD 600 avis · 599 avec aspect
1 592 couples

- Une personne, avec échanges et validations avec DeepSeek. Décisions finales humaines.
- Étoiles masquées. Cas ambigus tranchés puis généralisés.

SILVER 1 400 avis · 1 395 avec aspect
3 764 couples

- Annotation automatique par DeepSeek, selon le guide des 18 aspects.
- Relecture très partielle. Qualité d'ensemble non mesurée.

Aspects : une colonne binaire par aspect
Sentiment : une ligne par couple avis × aspect

Avis (exemple fictif)	delivery	customer service	price	product
Late delivery, good support	1	1	0	0
Great product, high price	0	0	1	1
Great support	0	1	0	0

Train · 1 600 avis
400 GOLD + 1 200 SILVER
4 279 couples sentiment
issus de 1 594 avis

Test · 400 avis
200 GOLD + 200 SILVER
1 077 couples sentiment
issus de 400 avis

Aucun review_id commun entre train et test

★ 6 avis sans aspect : aucun couple sentiment. Le SILVER représente 75 % des avis du train

★ Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

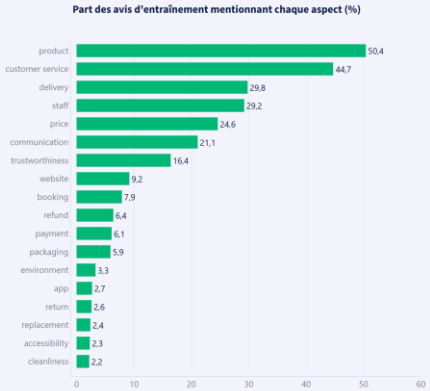
◀ Précéd... Suivante ▶

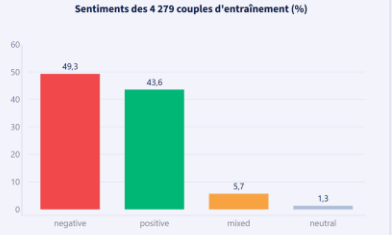
Ouverture Échantillon Ontologie Règles d'annotation GOLD et SILVER Déséquilibre Explorer les données

01 02 03 04 05

★ 02 · ANNOTATION

Des classes très déséquilibrées imposent le Macro-F1 comme critère





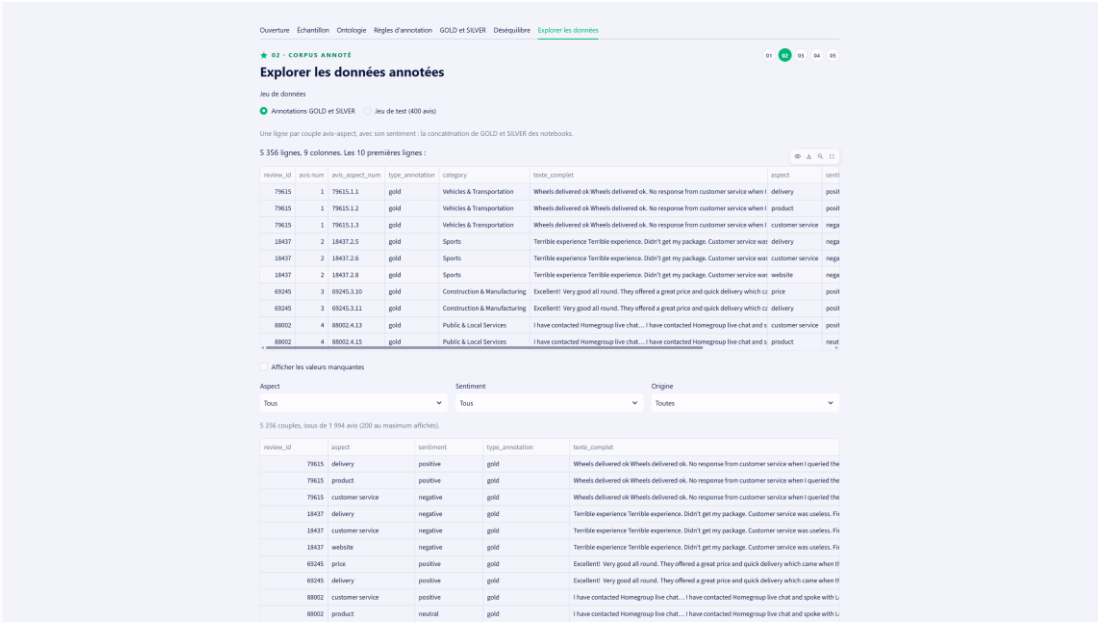
cleanliness : 36 avis sur 1 600. Répondre toujours « absent » donne 97,75 % de bonnes réponses… et aucune détection.

On juge donc chaque classe par son F1, puis on fait la moyenne.

★ Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶



★ Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd... Suivante ▶



★ Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd... Suivante ▶

★ 03 · MODÈLES CLASSIQUES

01 02 03 04 05

TF-IDF et un classifieur par aspect, comparés à une référence naïve

Texte de l'avis
titre + corps

→

TF-IDF
mots et bigrammes, min_df = 2
14 705 variables

→

One-vs-Rest
18 classifieurs binaires
class_weight balanced (LR, SVM)

→

18 décisions
présent / absent

Référence naïve
DummyClassifier stratifié : Micro-F1 0,307, Macro-F1 0,140, sans lire le texte

Validation croisée à 5 plis (CV)
TF-IDF réappris dans chaque pli (Pipeline) pour choisir le modèle à optimiser

Séparation par avis
Toutes les lignes d'un avis restent dans le même pli avec GroupKFold pour le sentiment

TF-IDF appris sur le train uniquement
Vocabulaire et poids IDF appris sur les 1 600 avis du train, puis appliqués au test

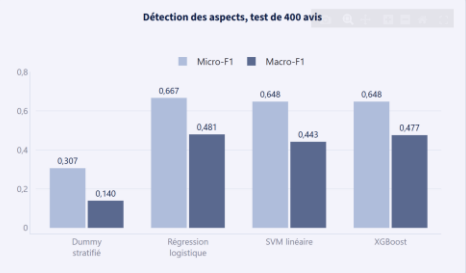
★ Un modèle plus complexe n'a d'intérêt que s'il fait mieux que ces références

★ Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd... Suivante ▶

★ 03 · MODÈLES CLASSIQUES · TÂCHE 1

01 02 03 04 05

Trois baselines loin devant le hasard ; la LR en tête en validation croisée



Validation croisée à 5 plis sur le train (moyenne ± écart-type)

Modèle	Micro-F1	Macro-F1
Régression logistique	0,637 ± 0,012	0,439 ± 0,025
XGBoost	0,612 ± 0,005	0,435 ± 0,018
SVM linéaire	0,622 ± 0,014	0,397 ± 0,014

- +0,341 de Macro-F1 sur le test par rapport au dummy
- Avance de 0,004 seulement sur XGBoost, inférieure à l'écart-type : un choix pragmatique

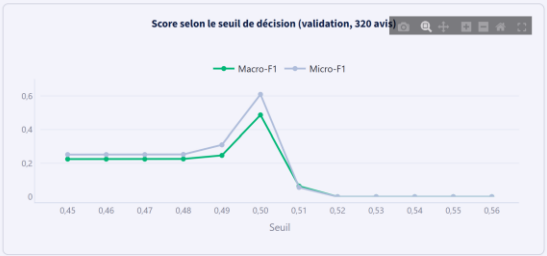
★ La régression logistique est retenue pour l'optimisation, sans supériorité nette démontrée

★ 03 · MODÈLES CLASSIQUES · TÂCHE 1

Optimiser C échange de la précision contre du rappel ; le seuil reste à 0,5

GridSearchCV retient C = 0,01 (liblinear)

Macro-F1	0,481 → 0,524	+0,043
Micro-F1	0,667 → 0,615	−0,052
Précision price	0,636 → 0,441	−0,195
Rappel price	0,670 → 0,840	+0,170



F1 nul dès 0,52 : aucun aspect correctement retrouvé. Ce résultat ne suffit pas à affirmer qu'aucune prédiction n'a été produite.

★ Le seuil reste à 0,5 : le score de validation chute dès 0,51 et devient nul à partir de 0,52

★ Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

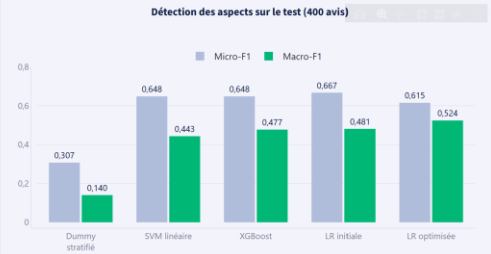
◀ Précéd... Suivante ▶

Ouverture Protocole Baselines Optimiser C Optimisation LR Coefficients Sentiment

01 02 03 04 05

★ 03 · MODÈLES CLASSIQUES · TÂCHE 1

Optimiser la LR sur les aspects : un compromis précision–rappel



GridSearchCV retient C = 0,01 (liblinear)

- Validation croisée : la LR arrive en tête (Macro-F1 moyen 0,439 contre 0,435 pour XGBoost)
- Avec C = 0,01, le Macro-F1 passe de 0,481 à 0,524
- Le Micro-F1 recule de 0,667 à 0,615 : plus de détections, moins justes (précision de price : 0,636 → 0,441)
- Sur les avis GOLD, le gain de l'optimisation n'est que de +0,006

★ Le Macro-F1 progresse grâce à de meilleurs F1 sur plusieurs aspects rares. En parallèle, la hausse des faux positifs dégrade la précision et le Micro-F1.

★ Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

Ouverture Protocole Baselines Optimiser C Optimisation LR Coefficients Sentiment

01 02 03 04 05

★ 03 · INTERPRÉTATION

Ce que la LR a appris : des termes pertinents, mais aussi des mots vides

Aspect affiché

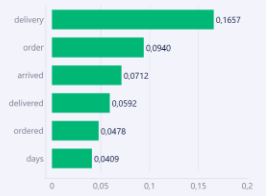
(•) Les trois ( ) packaging ( ) delivery ( ) trustworthiness

packaging F1 = 0,519



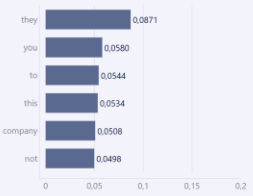
Emballage, carton, « bien emballé » : le sujet est bien cerné

delivery F1 = 0,760



Commande, arrivée, délai : un champ lexical cohérent

trustworthiness F1 = 0,439



Pronoms et mots vides : des associations de contexte à examiner

★ Les coefficients décrivent des associations apprises, pas des causes : ils orientent l'analyse des erreurs

★ 03 · MODÈLES CLASSIQUES · TÂCHE 2

Sentiment : les modèles classiques passent à côté de mixed et neutral



Matrice de confusion, régression logistique

☐ Afficher en % de la classe réelle

Sentiment réel \ Sentiment prédit	negative (571)	positive (429)	mixed (75)	neutral (2)
negative (551)	455	53	42	1
positive (454)	78	352	24	0
mixed (59)	30	19	9	1
neutral (13)	8	5	0	0

- mixed : 9/59 retrouvés, pour 75 prédictions
- mixed manqués : 30 prédits negative, 19 positive et 1 neutral
- neutral : 0/13 couple reconnu

★ L'optimisation n'apporte aucun gain : le Macro-F1 reste à 0,436, avec C = 1 retenu par validation croisée groupée par avis

★ Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

Ouverture Architecture Entraînement Résultats aspects GOLD et SILVER Par aspect Sentiment



★ Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

Ouverture Architecture Entraînement Résultats aspects GOLD et SILVER Par aspect Sentiment

01 02 03 04 05

★ 04 · DISTILBERT

DistilBERT lit l'avis en contexte : deux modèles fine-tunés, un par tâche

Pourquoi : TF-IDF compte des mots et des paires de mots ; l'attention relie chaque mot au reste de l'avis.

Modèle 1 aspects	Texte de l'avis — Tokenisé	→	DistilBERT — pré-entraîné, puis fine-tuné	→ 18 logits → sigmoïde — seuil 0,5 · perte BCEWithLogits	→ 0 à 18 aspects
Modèle 2 sentiment	Aspect + texte — ex. « delivery » + l'avis	→	DistilBERT — second modèle, fine-tuné à part	→ 4 logits → argmax — une classe par couple	→ 1 sentiment par couple

5×10^{-5} taux d'apprentissage	8 / 16 batch train / évaluation	0,01 weight decay	128 tokens maximum par texte

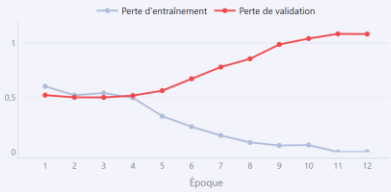
distilbert-base-uncased : environ 40 % de paramètres en moins que BERT. Entraînement sur CPU ; un essai BERT-base a été arrêté après 2 époques.

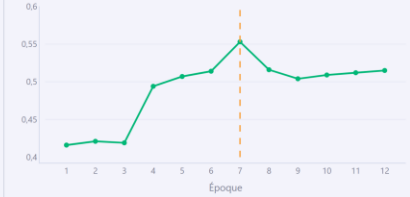
Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

★ 04 · DISTILBERT · ENTRAÎNEMENT

Les époques sont choisies sur le Macro-F1 de validation, pas sur la perte





Aspects · 11 époques
Validation 1 280 / 320 avis ; meilleur Macro-F1 de validation 0,372 à l'époque 11 ; réentraînement sur les 1 600 avis

Sentiment · 7 époques
Validation séparée par avis : 3 447 / 832 couples ; pic de Macro-F1 à 0,553 ; réentraînement sur les 4 279 couples

★ La perte de validation remonte dès l'époque 4, mais le Macro-F1 culmine à l'époque 7, retenue

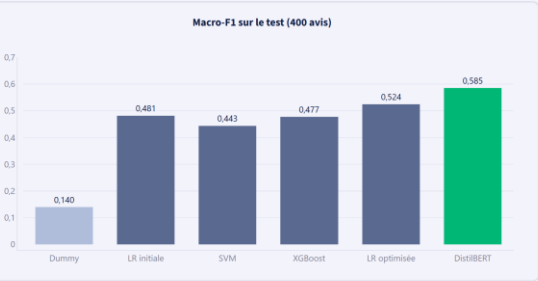
Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

★ 04 · DISTILBERT · TÂCHE 1

Détection des aspects : DistilBERT dépasse tous les modèles classiques



0,585
Macro-F1
+0,061 vs LR optimisée (0,524)

0,745
Micro-F1
+0,078 vs LR initiale (0,667)

Plus prudent
précision micro 0,800
rappel micro 0,697

★ DistilBERT améliore les deux métriques à la fois, là où l'optimisation de la LR en sacrifiait une

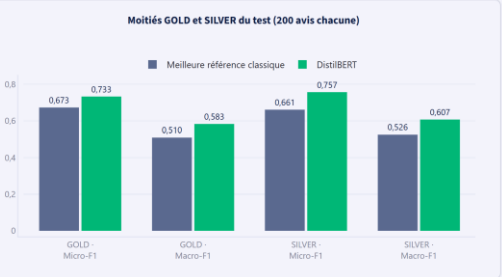
Aspect Intelligence

Sommaire
- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

★ 04 · DISTILBERT · TÂCHE 1

DistilBERT progresse aussi sur le GOLD vérifié manuellement



GOLD +0,060 / +0,073
Micro / Macro-F1 sur le GOLD vérifié et validé par l'annotateur

SILVER +0,096 / +0,081
Accord avec les labels produits par le LLM

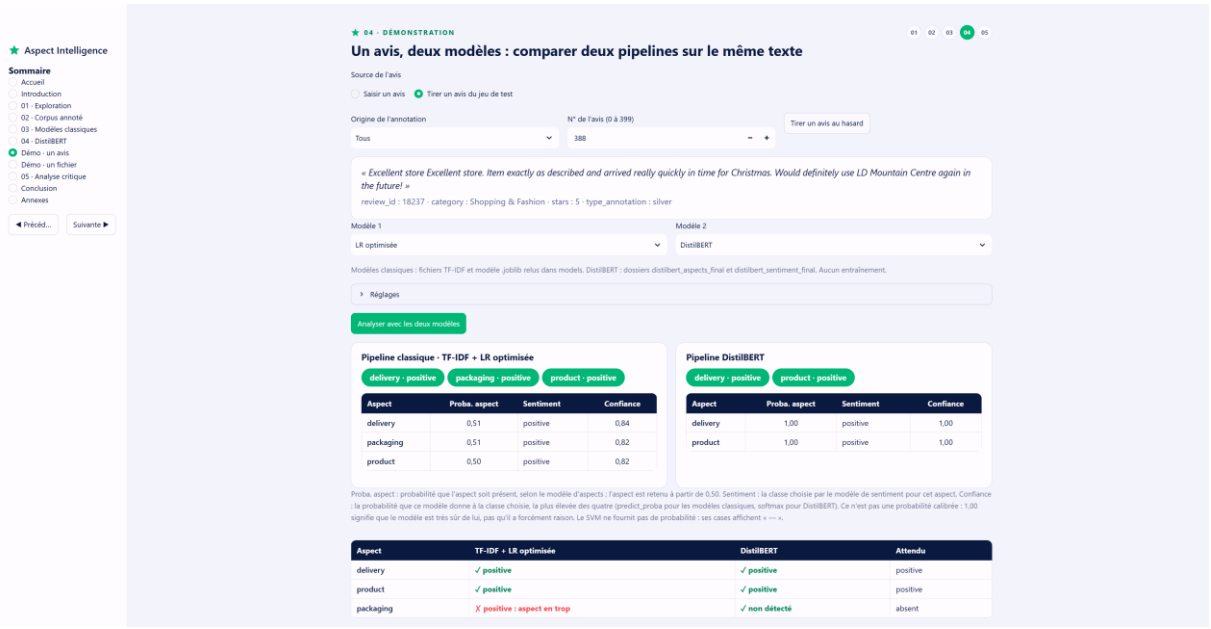
Les deux moitiés diffèrent aussi par leurs textes et leurs aspects : leur écart ne s'attribue pas au seul LLM.

Références classiques : LR initiale pour le Micro-F1, LR optimisée pour le Macro-F1.

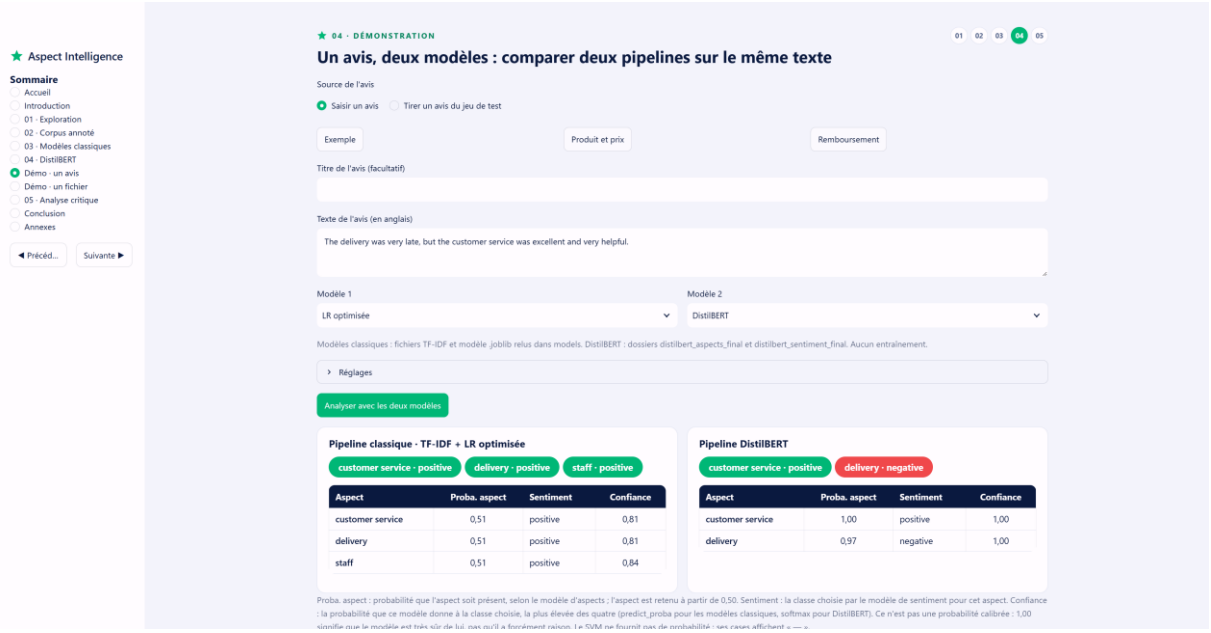
★ Sur GOLD : Macro-F1 de 0,510 pour la LR optimisée et 0,583 pour DistilBERT, soit +0,073


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
Ouverture Architecture Entraînement Résultats aspects GOLD et SILVER Par aspect Sentiment
★ 04 · DISTILBERT · TÂCHE 1
01 02 03 04 05
Face à la LR optimisée, DistilBERT progresse sur 14 des 18 aspects
Trier les aspects par
Nombre d'avis concernés
Gain de DistilBERT
F1 de DistilBERT
F1 par aspect sur le test (nombre d'avis concernés)
DistilBERT
LR optimisée
product (215)
customer service (176)
delivery (135)
staff (112)
price (94)
communication (78)
trustworthiness (63)
booking (36)
website (36)
refund (28)
payment (22)
packaging (17)
app (14)
environment (13)
accessibility (12)
return (12)
cleanliness (8)
replacement (6)
0
0,2
0,4
0,6
0,8
1
Gains de F1 vs LR optimisée
packaging +0,329
refund +0,306
environment +0,231
price +0,225
Reculs et cas retrouvés
cleanliness : 1 sur 8
replacement : 0 sur 6
accessibility : 1 sur 12
trustworthiness : −0,015
Six aspects ont moins de 15 avis de test. Un seul cas peut faire varier leur F1.


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
Ouverture Architecture Entraînement Résultats aspects GOLD et SILVER Par aspect Sentiment
★ 04 · DISTILBERT · TÂCHE 2
01 02 03 04 05
Sentiment : le gain le plus net porte sur mixed et neutral
0,829
Accuracy
+4,5 pts vs SVM (0,784)
0,577
Macro-F1
+0,141 vs LR (0,436)
0,830
Weighted-F1
+0,062 vs SVM (0,768)
F1 par sentiment sur le test (nombre de couples)
Régression logistique
DistilBERT
1
0,8
0,6
0,4
0,2
0
0,811
0,875
0,797
0,852
0,134
0,369
0,000
0,211
negative (551)
positive (454)
mixed (59)
neutral (13)
Matrice de confusion, DistilBERT
Afficher en % de la classe réelle
Sentiment prédit
negative
positive
mixed
neutral
Sentiment réel
negative 491 33 24 3
positive 54 376 23 1
mixed 17 18 24 0
neutral 9 2 0 2
mixed : 24 couples sur 59 retrouvés, contre 9 pour la LR
neutral : 2 sur 13, une classe encore fragile (57 exemples d'entraînement)
negative et positive : F1 au-dessus de 0,85
893 couples bien classés sur 1 077


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶
04 · DÉMONSTRATION
01 02 03 04 05
Un avis, deux modèles : comparer deux pipelines sur le même texte
Source de l'avis
Saisir un avis
Tirer un avis du jeu de test
Origine de l'annotation
Tous
N° de l'avis (0 à 399)
388
Tirer un avis au hasard
« Excellent store Excellent store. Item exactly as described and arrived really quickly in time for Christmas. Would definitely use LD Mountain Centre again in the future! »
review_id : 18237 · category : Shopping & Fashion · stars : 5 · type_annotation : silver
Modèle 1
LR optimisée
Modèle 2
DistilBERT
Modèles classiques : fichiers TF-IDF et modèle .joblib relus dans models. DistilBERT : dossiers distilbert_aspects_final et distilbert_sentiment_final. Aucun entraînement.
Réglages
Analyser avec les deux modèles
Pipeline classique · TF-IDF + LR optimisée
delivery · positive
packaging · positive
product · positive
Aspect
Proba. aspect
Sentiment
Confiance
delivery 0,51 positive 0,84
packaging 0,51 positive 0,82
product 0,50 positive 0,82
Pipeline DistilBERT
delivery · positive
product · positive
Aspect
Proba. aspect
Sentiment
Confiance
delivery 1,00 positive 1,00
product 1,00 positive 1,00
Proba. aspect : probabilité que l'aspect soit présent, selon le modèle d'aspects ; l'aspect est retenu à partir de 0,50. Sentiment : la classe choisie par le modèle de sentiment pour cet aspect. Confiance : la probabilité que ce modèle donne à la classe choisie, la plus élevée des quatre (predict_proba pour les modèles classiques, softmax pour DistilBERT). Ce n'est pas une probabilité calibrée : 1,00 signifie que le modèle est très sûr de lui, pas qu'il a forcément raison. Le SVM ne fournit pas de probabilité : ses cases affichent « — ».
Aspect
TF-IDF + LR optimisée
DistilBERT
Attendu
delivery ✓ positive ✓ positive positive
product ✓ positive ✓ positive positive
packaging ✗ positive : aspect en trop ✓ non détecté absent


Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précé...
Suivante ...
Attendu : le sentiment annoté pour cet aspect, ou « absent » si l'annotation ne contient pas l'aspect. ✓ : comme l'annotation. ✗ aspect en trop : détecté alors que l'annotation ne le contient pas. ✗ non détecté : annoté mais manqué. ✗ sentiment faux : bon aspect, mauvais sentiment.
Probabilités des 18 aspects pour les deux modèles
Probabilité de chaque aspect (pointillés : seuil de 0,50)
TF-IDF + LR optimisée
DistilBERT
accessibility
app
booking
cleanliness
communication
customer service
delivery
environment
packaging
payment
price
product
refund
replacement
return
staff
trustworthiness
website
0
0.2
0.4
0.6
0.8
1
La falaise observée en validation lors du choix du seuil suggérait des probabilités de la LR optimisée (C = 0,01) très concentrées autour de 0,5 : ce graphique permet de le vérifier sur cet avis.
Ce que TF-IDF + LR optimisée a lu : fichiers et termes TF-IDF
Fichiers chargés depuis models\ (aucun entraînement)
tfidf_aspects.joblib
liste_aspects.joblib
modele_lr_opt_aspects.joblib
tfidf_sentiments.joblib
modele_lr_opt_sentiments.joblib
Les 10 termes les plus pondérés par tfidf_aspects
Terme
Poids TF-IDF
store 0,327
quickly in 0,241
excellent 0,239
exactly as 0,224
and arrived 0,218
Termes qui ont poussé vers chaque aspect détecté
delivery : arrived (0,008), item (0,005), quickly (0,003), as described (0,003), described (0,002)
packaging : arrived (0,010), in (0,006), item (0,005), exactly as (0,004), as described (0,004)
product : the (0,002), described (0,002), as described (0,002), in (0,002), christmas (0,002)
Associations apprises, pas des causes (comme la slide Coefficients).



▾ Ce que TF-IDF + LR optimisée a lu : fichiers et termes TF-IDF

Fichiers chargés depuis models\ (aucun entraînement)

- tfidf_aspects.joblib
- liste_aspects.joblib
- modele_lr_opt_aspects.joblib
- tfidf_sentiments.joblib
- modele_lr_opt_sentiments.joblib

Les 10 termes les plus pondérés par tfidf_aspects

Terme	Poids TF-IDF
store	0,327
quickly in	0,241
excellent	0,239
exactly as	0,224
and arrived	0,218
for christmas	0,218
definitely use	0,218
described and	0,213
again in	0,213
in time	0,198

Termes qui ont poussé vers chaque aspect détecté

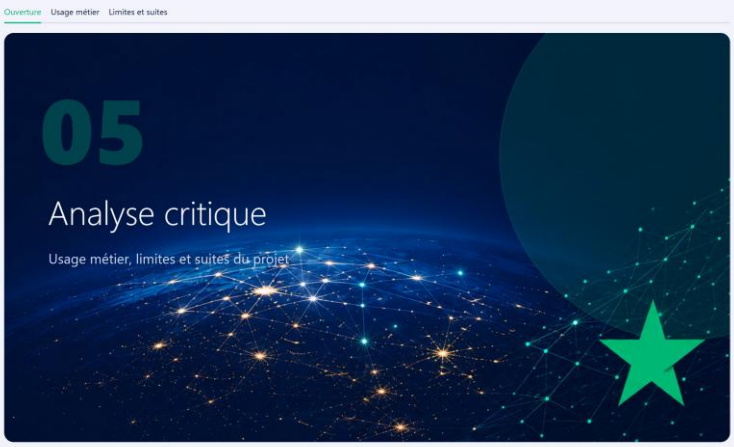
delivery : arrived (0,008), item (0,005), quickly (0,003), as described (0,003), described (0,002)

packaging : arrived (0,010), in (0,006), item (0,005), exactly as (0,004), as described (0,004)

product : the (0,002), described (0,002), as described (0,002), in (0,002), christmas (0,002)

Associations apprises, pas des causes (comme la slide Coefficients).

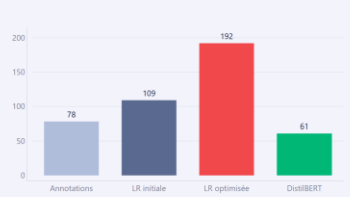
★ **Une illustration sur un exemple : la chaîne complète n'a pas encore de score chiffré sur le test**



Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶

★ 05 · ANALYSE CRITIQUE

Pour un usage métier, la précision compte autant que le score global



×2,46

Tableau de bord faussé

48 % des avis signalés par la LR optimisée pour communication, contre 19,5 % annotés (DistilBERT : 15,25 %).

Elle signale 192 avis, dont 126 à tort (66 corrects), pour 78 avis réellement concernés : elle surestime fortement le volume.

+0,006

Aspects rares très sensibles

LR optimisée : corriger un seul faux négatif sur replacement porterait son F1 de 0,286 à 0,400, soit environ +0,006 de Macro-F1 global.

Validations non directement comparables

LR : 0,487 pour choisir le seuil. DistilBERT : 0,372 pour choisir l'époque. Les procédures diffèrent. Ces scores ne mesurent pas un renversement du classement.

DistilBERT : 61 avis signalés, pour 78 réellement concernés

Correctement repérés	Signalés à tort	Manqués
40	21	38

★ La robustesse des écarts reste à confirmer par un protocole commun et un bootstrap apparié par avis

Aspect Intelligence
Sommaire
Accueil
Introduction
01 · Exploration
02 · Corpus annoté
03 · Modèles classiques
04 · DistilBERT
Démo · un avis
Démo · un fichier
05 · Analyse critique
Conclusion
Annexes
◀ Précéd...
Suivante ▶

★ 05 · LIMITES ET SUITES

Sept limites à lever avant un usage réel, et une piste pour chacune

	Limite	Constat	Prochaine étape
	Classes rares	accessibility 1/12, cleanliness 1/8, replacement 0/6 ; neutral : F1 0,211	Annoter plus de GOLD sur ces aspects, ainsi que sur mixed et neutral
	Précision et rappel	Rappel de DistilBERT : 0,513 sur communication, 0,333 sur trustworthiness	Seuil par aspect testé sur une validation indépendante, selon l'usage visé
	Annotations SILVER	75 % des avis du train et 50 % des avis du test sont SILVER ; leur qualité globale n'a pas été mesurée.	Relire un échantillon SILVER ; évaluer le sentiment séparément sur GOLD et SILVER
	Protocole	Choix du modèle de sentiment sur le test. TF-IDF appris avant les plis lors des recherches d'hyperparamétres.	Pipeline dans chaque pli, validation croisée avant sélection, nouveau test réservé
	Chaîne complète	Sentiment évalué avec les aspects annotés : pas de score de bout en bout	Mesurer aspects ajoutés, oubliés et sentiments faux, puis analyser sur GOLD
	Représentativité	Plafond de 20 avis par note et par entreprise ; avis UK, en anglais	Évaluer sur un flux d'avis réel, tiré sans plafond par note
	Calcul	CPU uniquement : 128 tokens, BERT-base arrêté après 2 époques	GPU pour tester la longueur maximale et la pondération de la perte

★ Aspect Intelligence

Sommaire

- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

★ SYNTHÈSE

DistilBERT retenu : meilleurs résultats observés sur les deux tâches

0,745
Micro-F1 · aspects
+0,078 vs LR initiale

0,585
Macro-F1 · aspects
+0,061 vs LR optimisée

0,829
Accuracy · sentiment
+4,5 pts vs SVM

0,577
Macro-F1 · sentiment
+0,141 vs LR

1. **Un corpus riche, mais biaisé**
   123 181 avis Hugging Face, plafonnés à 20 avis par note et par entreprise
2. **2 000 avis annotés sur 18 aspects**
   600 avis GOLD vérifiés, 1 400 avis SILVER produits par un LLM ; 1 994 avec au moins un aspect et 5 356 couples annotés
3. **DistilBERT dépasse les modèles classiques**
   Hausse sur les quatre métriques ; +0,073 sur GOLD (aspects)
4. **Des limites avant un usage réel**
   Classes rares, qualité du SILVER, chaîne complète non mesurée

Merci de votre attention. Questions ?

★ Aspect Intelligence

Sommaire

- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

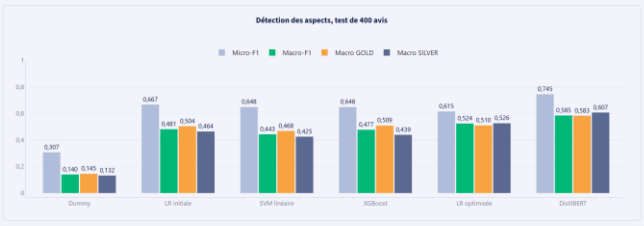
Six configurations 18 aspects Sources

★ ANNEXE

Scores des six configurations sur le même test

Tâche
- Détection des aspects
- Sentiment par aspect

Modèles à comparer: Dummy × LR initiale × SVM linéaire × XGBoost × LR optimisée × DistilBERT ×



Modèle	Micro-F1	Macro-F1	Macro GOLD	Macro SILVER	Accuracy (sent.)	Macro-F1 (sent.)	Weighted-F1 (sent.)
Dummy	0,307	0,140	0,145	0,132	0,512	0,169	0,346
LR initiale	0,667	0,481	0,504	0,464	0,758	0,436	0,758
SVM linéaire	0,648	0,443	0,468	0,425	0,784	0,431	0,768
XGBoost	0,648	0,477	0,509	0,439	0,773	0,407	0,750
LR optimisée	0,615	0,524	0,510	0,526	0,758	0,436	0,758
DistilBERT	**0,745**	**0,585**	**0,583**	**0,607**	**0,829**	**0,577**	**0,830**

Colonnes 2 à 5 : aspects, test de 400 avis. Colonnes 6 à 8 : sentiment, 1 077 couples. Dummy : stratifié pour les aspects, majoritaire (toujours negative) pour le sentiment. LR optimisée, sentiment : C = 1 conservé, scores identiques à la LR initiale.

★ Aspect Intelligence

Sommaire

- Accueil
- Introduction
- 01 · Exploration
- 02 · Corpus annoté
- 03 · Modèles classiques
- 04 · DistilBERT
- Démo · un avis
- Démo · un fichier
- 05 · Analyse critique
- Conclusion
- Annexes

◀ Précéd... Suivante ▶

Six configurations 18 aspects Sources

★ ANNEXE

Scores détaillés des 18 aspects sur les 400 avis de test

Aspect	n	F1 LR	F1 DistilBERT
product	215	0,761	0,827
customer service	176	0,751	0,785
delivery	135	0,760	0,861
staff	112	0,679	0,811
price	94	0,579	0,804
communication	78	0,489	0,576
trustworthiness	63	0,439	0,424
booking	36	0,442	0,552
website	36	0,541	0,656

Aspect	n	F1 LR	F1 DistilBERT
refund	28	0,458	0,764
payment	22	0,400	0,457
packaging	17	0,519	0,848
app	14	0,552	0,600
environment	13	0,245	0,476
accessibility	12	0,333	0,154
return	12	0,667	0,762
cleanliness	8	0,526	0,182
replacement	6	0,286	0,000

n : nombre d'avis annotés avec l'aspect. LR : configuration optimisée. En vert, DistilBERT fait mieux ; en rouge, il recule. Les très petits supports rendent le F1 instable.