Trustpilot

SOUTENANCE DU PROJET

Trustpilot
Aspect Intelligence

Détecter de quoi parlent les clients, et ce qu'ils en pensent

Analyse de sentiment par aspect (ABSA) sur les avis Trustpilot



19 octobre 2026

DÉMARCHE

Une démarche en deux étapes successives

01

Exploration et choix du corpus

- Comparaison de Kaggle et Hugging Face
- Analyse des textes et des notes
- Identification des biais de collecte

02

Annotation, modèles et évaluation

- Construction progressive des 18 aspects
- Comparaison TF-IDF et DistilBERT
- Interprétation des scores et des erreurs

Les choix méthodologiques se précisent au fil du projet

LE BESOIN

Une note sur 5 résume l'expérience, sans dire ce qu'il faut améliorer

Un même avis, deux sujets, deux appréciations

« The delivery was very late, but the customer service was excellent and very helpful. »

La note globale donne une seule valeur, de 1★ à 5★, pour tout l'avis

Ce que l'entreprise veut savoir

delivery · negative

customer service · positive

Repérer les irritants

Suivre les thèmes négatifs qui reviennent

Comparer les secteurs

Lire les aspects selon la catégorie d'activité

Prioriser les actions

Moins de lecture manuelle, plus de décisions

Objectif : retrouver chaque aspect exprimé dans un avis et lui associer son propre sentiment

NOTRE APPROCHE

Le pipeline d'analyse : deux modèles enchaînés



Tâche 1 · détection des aspects

- Classification multi-label : plusieurs aspects par avis
- 18 aspects métier, de product à accessibility
- Métriques : Micro-F1 et Macro-F1

Tâche 2 · sentiment par aspect

- Classification multiclasse : un sentiment par couple
- Entrée : nom de l'aspect + texte de l'avis
- Métriques : Accuracy, Macro-F1 et Weighted-F1

Critère principal : le Macro-F1, qui donne le même poids à chaque aspect et à chaque sentiment, même rare

DÉMARCHE

Cinq étapes, de l'exploration des avis au modèle retenu

01

Explorer

Comparer deux corpus publics, repérer les biais de collecte

123 181 avis

Slides 6 à 9

02

Annoter

Échantillonner, construire l'ontologie, annoter GOLD et SILVER

18 aspects

Slides 10 à 15

03

Modèles classiques

TF-IDF avec régression logistique, SVM et XGBoost

0,524 Macro-F1

Slides 16 à 22

04

DistilBERT

Fine-tuning de deux modèles, un par tâche, sur CPU

0,585 Macro-F1

Slides 23 à 30

05

Analyse critique

Usage métier, limites et suites du projet

7 limites

Slides 31 à 33

En annexe : scores des six configurations, détail des 18 aspects et sources du projet

01

Exploration des données

Comparer deux corpus publics, repérer les biais de collecte



Deux corpus publics comparés : Hugging Face apporte volume et diversité

	Kaggle	Hugging Face
Avis	3 698	**123 181**
Entreprises	214	**1 680**
Catégories	non structurées	**22**
Longueur médiane	159 caractères	**290 caractères**
Avis par entreprise (max)	20	**100**
Dates des avis	oui	**non**
Valeurs manquantes	686 (description)	**aucune**

Seulement 7 avis communs. Kaggle sert à la comparaison exploratoire. L'évaluation externe des modèles reste à réaliser.

33,3 fois

plus d'avis dans Hugging Face que dans Kaggle

7

avis communs seulement : les deux corpus sont distincts

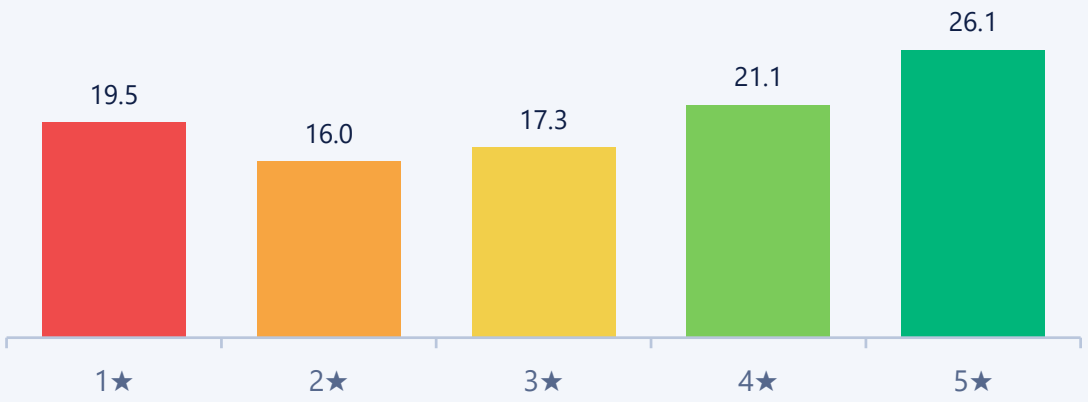
Trustpilot UK

source de Hugging Face, avis majoritairement en anglais

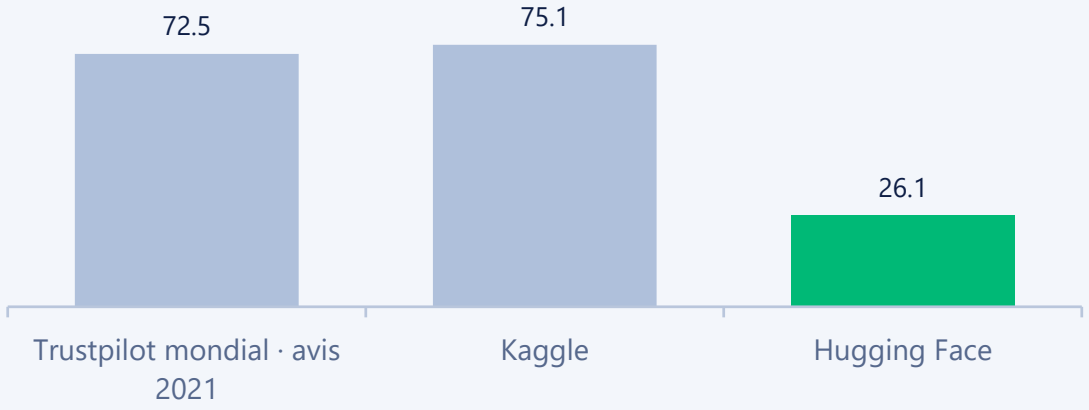
Hugging Face devient le corpus principal ; Kaggle reste un corpus de contrôle (dates, distribution des notes)

Un plafond de 20 avis par note et par entreprise rééquilibre les notes

Répartition des notes, Hugging Face (%)



Part des avis 5★ selon la source (%)



Une entreprise à 20 avis par note :
(20×1 + 20×2 + 20×3 + 20×4 + 20×5) / 100 = 3

558
entreprises avec exactement 20 avis par note

611
entreprises à moyenne exactement égale à 3

χ^2 = 4 559,54
p ≈ 0 : distributions Kaggle et HF différentes

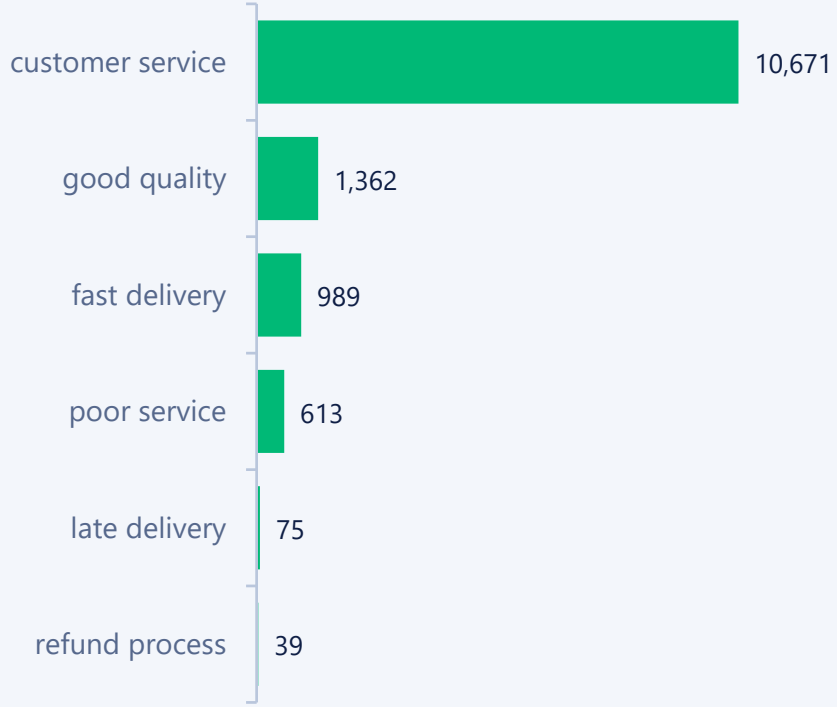
Un bon corpus pour apprendre le langage des avis, pas pour mesurer la satisfaction réelle

Le vocabulaire des avis est riche, mais le sens dépend du contexte

Rang des mots métier parmi 73 755 formes

service	6e
delivery	12e
order	17e
customer	26e
quality	79e
price	81e

Expressions liées aux aspects



Le piège des négations

« not good »	775
« not great »	474
« not easy »	197
« not helpful »	189

Compter « good » comme positif sans lire la phrase conduirait à des erreurs.

Un comptage de mots ne suffit pas : il faut un modèle qui lit le contexte

02

Corpus annoté

Échantillonner, construire l'ontologie, annoter GOLD et SILVER



2 000 avis stratifiés par catégorie et par note, fidèles au corpus retenu

123 181 avis
corpus Hugging Face

↓

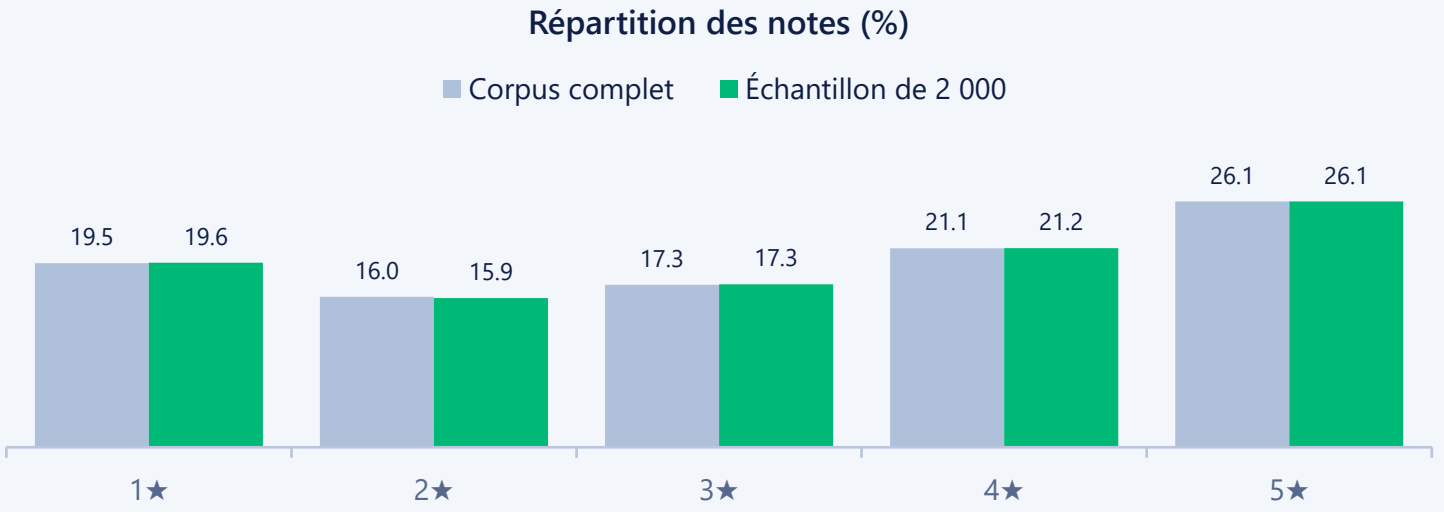
2 000 avis
strates catégorie × note (110 strates)

↓

600 avis
corpus pilote → GOLD

1 400 avis
reste → SILVER

Richesse lexicale (faible / moyenne / forte) : pilote 40,5 / 33,3 / 26,2 %, échantillon 39,6 / 33,8 / 26,6 %



0,13 pt
écart maximal sur la part d'une note

0,08 pt
écart maximal sur une catégorie

281 / 290
caractères, longueur médiane

19 / 20
mots les plus fréquents communs

Fidèle au corpus retenu, l'échantillon hérite aussi de son plafond de 20 avis par note et par entreprise

Une ontologie de 18 aspects construite sur les 600 avis pilotes

Construction progressive

1. Lecture libre des avis pilotes
2. Regroupement des formulations proches
3. Test des catégories sur d'autres avis
4. Fusion, séparation ou ajout
5. **Ontologie stabilisée : 18 aspects**

18 aspects

accessibility	app	booking
cleanliness	communication	customer service
delivery	environment	packaging
payment	price	product
refund	replacement	return
staff	trustworthiness	website

4 sentiments, par aspect

positive	appréciation favorable
negative	appréciation défavorable
neutral	aspect mentionné, sans appréciation
mixed	favorable et défavorable sur le même aspect

Une ligne par avis et par aspect · mentions regroupées · étoiles masquées (GOLD)

Deux aspects aux sentiments opposés ne font pas un mixed : chacun reçoit son propre sentiment

Des aspects proches, des objets évalués différents

Le sujet évalué guide l'aspect. Les mots employés ne suffisent pas à trancher.

	Aspect	Ce qui est évalué	Exemple illustratif
	**staff**	Attitude, compétence ou comportement du personnel	*Un vendeur patient et aimable.*
	**customer service**	Prise en charge d'une demande ou résolution d'un problème	*Mon problème a été réglé rapidement.*
	**communication**	Information transmise, clarté des échanges et suivi	*Les mises à jour étaient claires et régulières.*

Un avis peut réunir plusieurs aspects, chacun avec son propre sentiment.

Les annotations comportent encore des chevauchements. Certains cas ambigus restent à harmoniser.

Le corpus GOLD constitue une référence vérifiée, avec des conventions et des limites explicites

GOLD et SILVER : un découpage commun au niveau de l'avis

GOLD

600 avis · 599 avec aspect
1 592 couples

- Une personne, avec échanges et validations avec DeepSeek. Décisions finales humaines.
- Étoiles masquées. Cas ambigus tranchés puis généralisés.

SILVER

1 400 avis · 1 395 avec aspect
3 764 couples

- Annotation automatique par DeepSeek, selon le guide des 18 aspects.
- Relecture très partielle. Qualité d'ensemble non mesurée.

Aspects : une colonne binaire par aspect

Sentiment : une ligne par couple avis × aspect

Avis (exemple fictif)	delivery	customer service	price	product
Late delivery, good support	1	1	0	0
Great product, high price	0	0	1	1
Great support	0	1	0	0

Train · 1 600 avis
400 GOLD + 1 200 SILVER
4 279 couples sentiment
issus de 1 594 avis

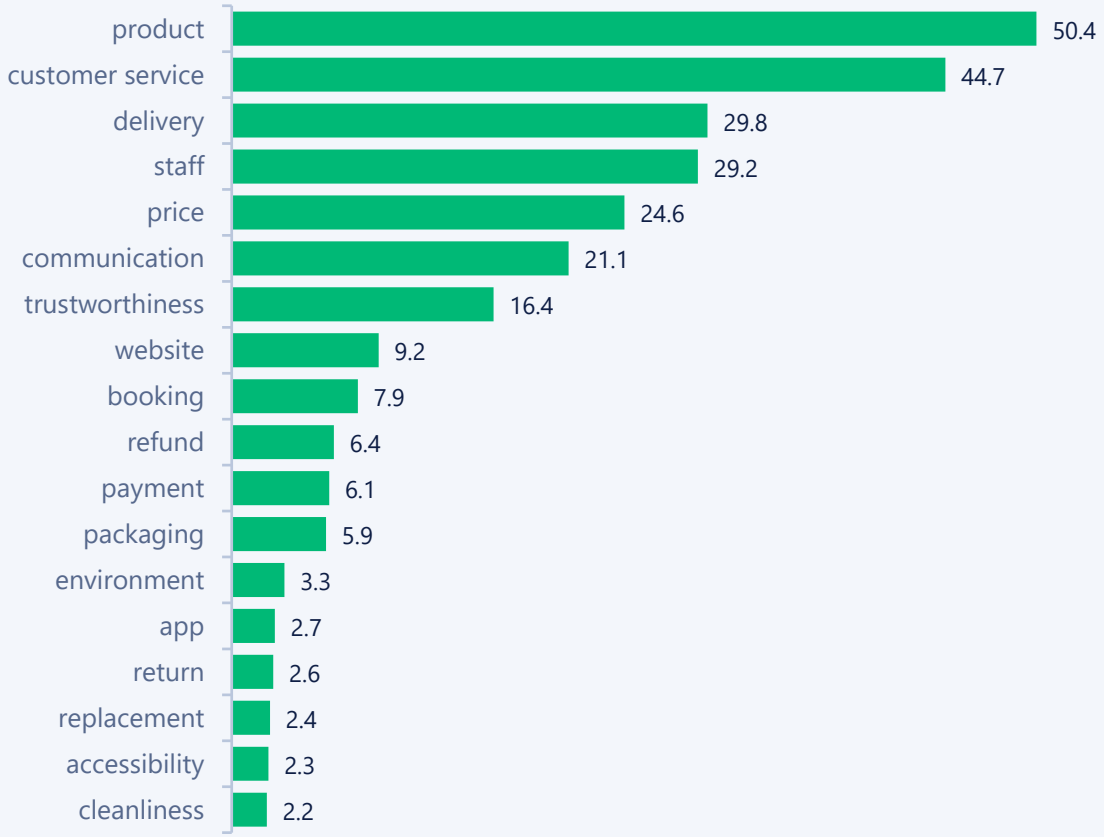
Test · 400 avis
200 GOLD + 200 SILVER
1 077 couples sentiment
issus de 400 avis

Aucun review_id commun entre train et test

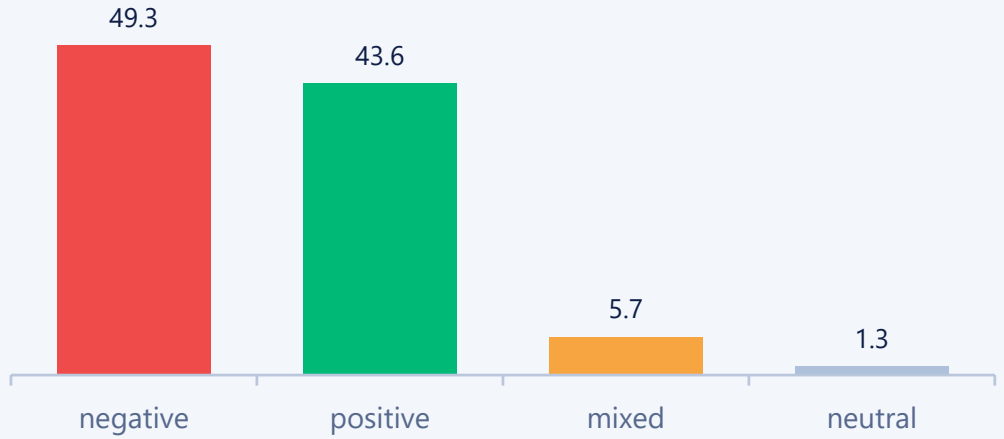
6 avis sans aspect : aucun couple sentiment. Le SILVER représente 75 % des avis du train

Des classes très déséquilibrées imposent le Macro-F1 comme critère

Part des avis d'entraînement mentionnant chaque aspect (%)



Sentiments des 4 279 couples d'entraînement (%)



cleanliness : 36 avis sur 1 600. Répondre toujours « absent » donne 97,75 % de bonnes réponses… et aucune détection.

On juge donc chaque classe par son F1, puis on fait la moyenne.

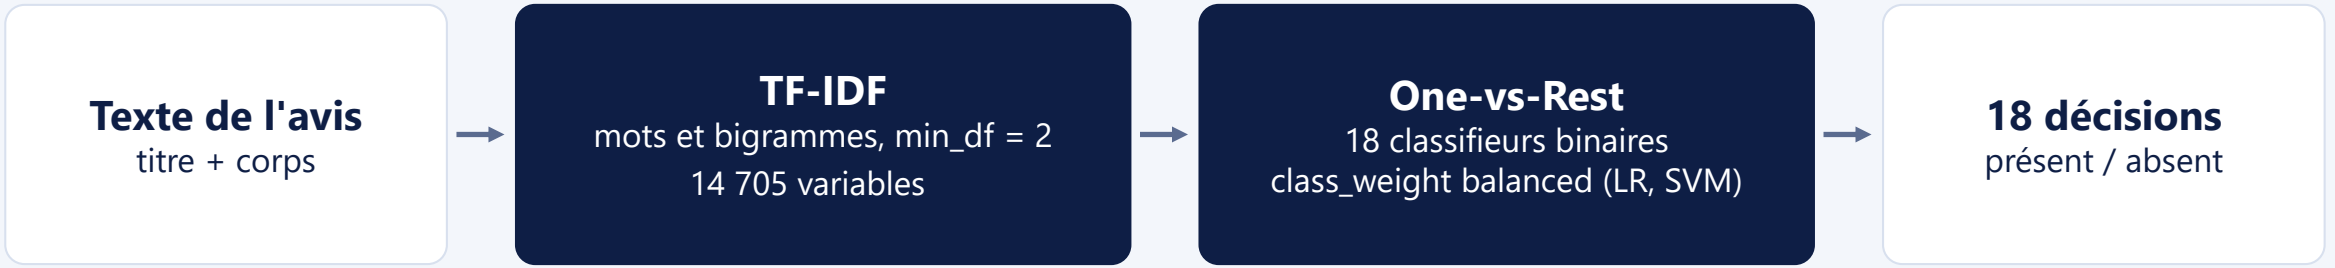
03

Modèles classiques

TF-IDF avec régression logistique, SVM et XGBoost



TF-IDF et un classifieur par aspect, comparés à une référence naïve



Référence naïve

DummyClassifier stratifié : Micro-F1 0,307, Macro-F1 0,140, sans lire le texte

Validation croisée à 5 plis (CV)

TF-IDF réappris dans chaque pli (Pipeline) pour choisir le modèle à optimiser

Séparation par avis

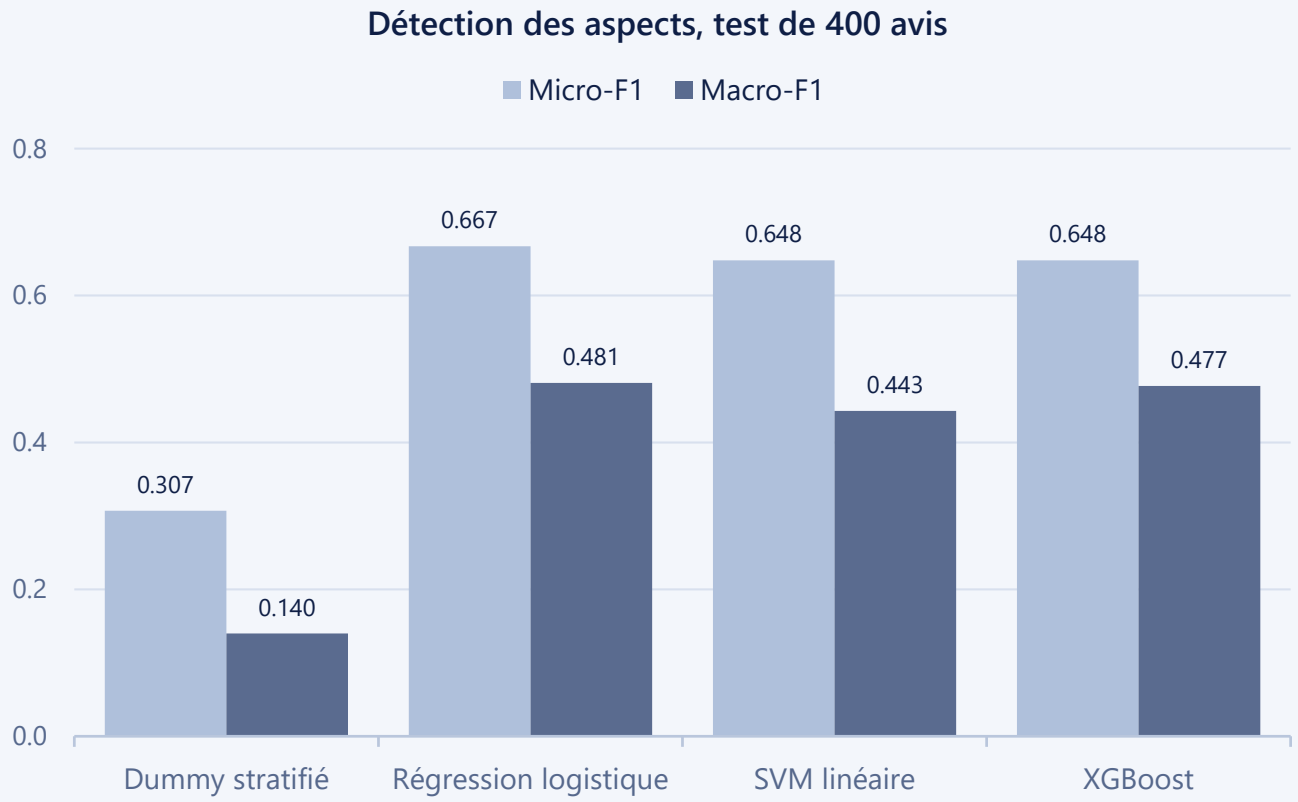
Toutes les lignes d'un avis restent dans le même pli avec GroupKFold pour le sentiment

TF-IDF appris sur le train uniquement

Vocabulaire et poids IDF appris sur les 1 600 avis du train, puis appliqués au test

Un modèle plus complexe n'a d'intérêt que s'il fait mieux que ces références

Trois baselines loin devant le hasard ; la LR en tête en validation croisée



Validation croisée à 5 plis sur le train (moyenne ± écart-type)

Modèle	Micro-F1	Macro-F1
Régression logistique	**0,637 ± 0,012**	**0,439 ± 0,025**
XGBoost	0,612 ± 0,005	0,435 ± 0,018
SVM linéaire	0,622 ± 0,014	0,397 ± 0,014

- +0,341 de Macro-F1 sur le test par rapport au dummy
- Avance de 0,004 seulement sur XGBoost, inférieure à l'écart-type : un choix pragmatique

La régression logistique est retenue pour l'optimisation, sans supériorité nette démontrée

Optimiser C échange de la précision contre du rappel ; le seuil reste à 0,5

GridSearchCV retient C = 0,01 (liblinear)

Macro-F1	0,481 → 0,524	**+0,043**
Micro-F1	0,667 → 0,615	**−0,052**
Précision price	0,636 → 0,441	**−0,195**
Rappel price	0,670 → 0,840	**+0,170**

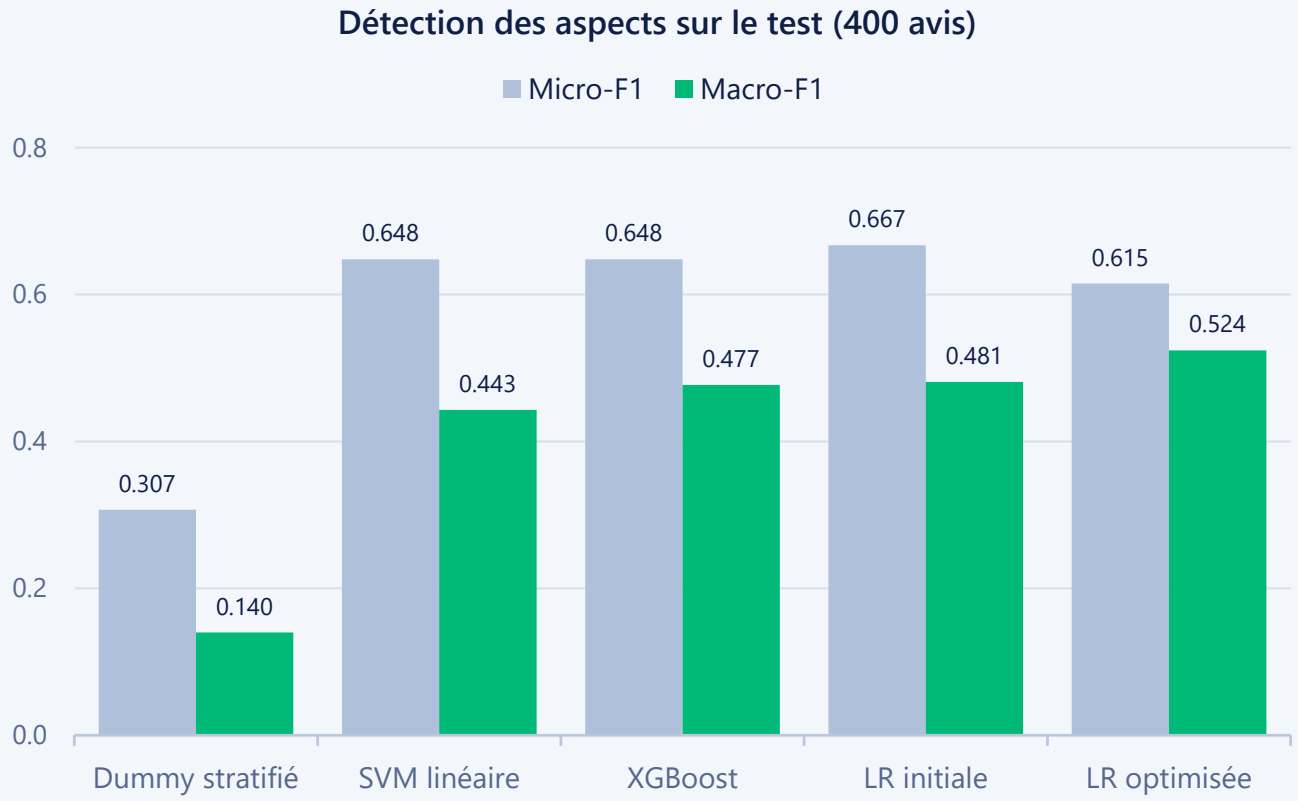
Score selon le seuil de décision (validation, 320 avis)



F1 nul dès 0,52 : aucun aspect correctement retrouvé. Ce résultat ne suffit pas à affirmer qu'aucune prédiction n'a été produite.

Le seuil reste à 0,5 : le score de validation chute dès 0,51 et devient nul à partir de 0,52

Optimiser la LR sur les aspects : un compromis précision–rappel



GridSearchCV retient C = 0,01 (liblinear)

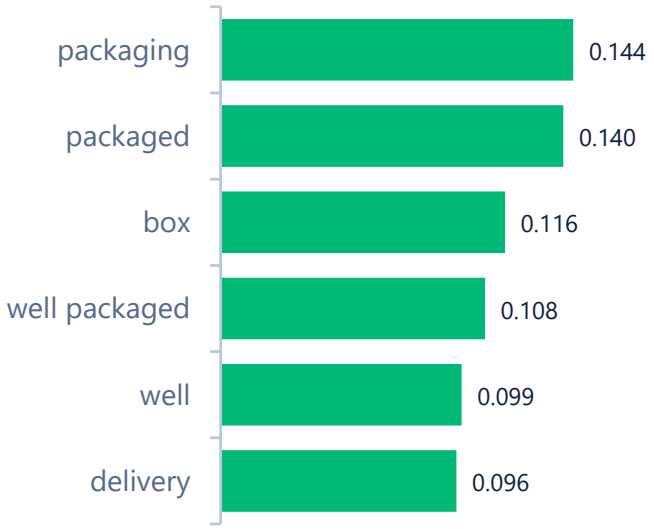
- Validation croisée : la LR arrive en tête (Macro-F1 moyen 0,439 contre 0,435 pour XGBoost)
- Avec C = 0,01, le Macro-F1 passe de 0,481 à **0,524**
- Le Micro-F1 recule de 0,667 à **0,615** : plus de détections, moins justes (précision de price : 0,636 → **0,441**)
- Sur les avis GOLD, le gain de l'optimisation n'est que de **+0,006**

Le Macro-F1 progresse grâce à de meilleurs F1 sur plusieurs aspects rares. En parallèle, la hausse des faux positifs dégrade la précision et le Micro-F1.

Ce que la LR a appris : des termes pertinents, mais aussi des mots vides

packaging

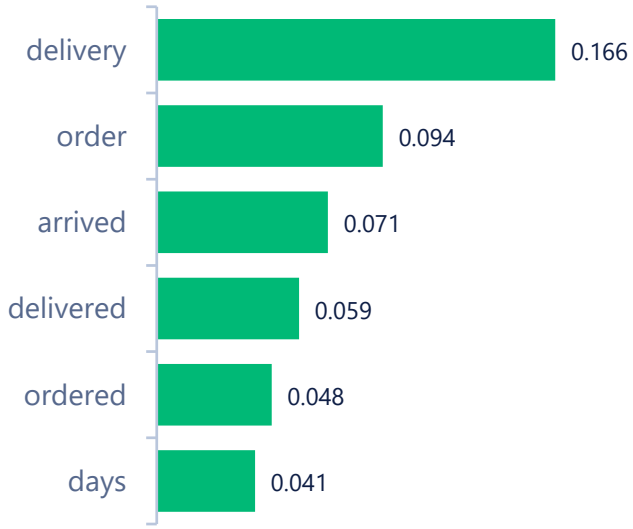
F1 = 0,519



Emballage, carton, « bien emballé » : le sujet est bien cerné

delivery

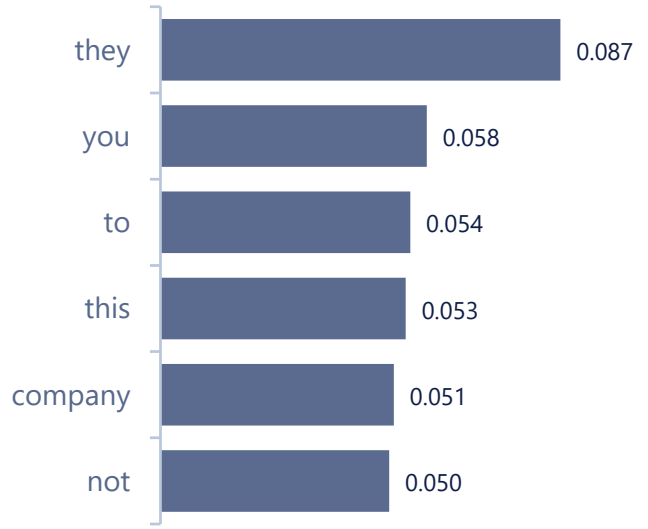
F1 = 0,760



Commande, arrivée, délai : un champ lexical cohérent

trustworthiness

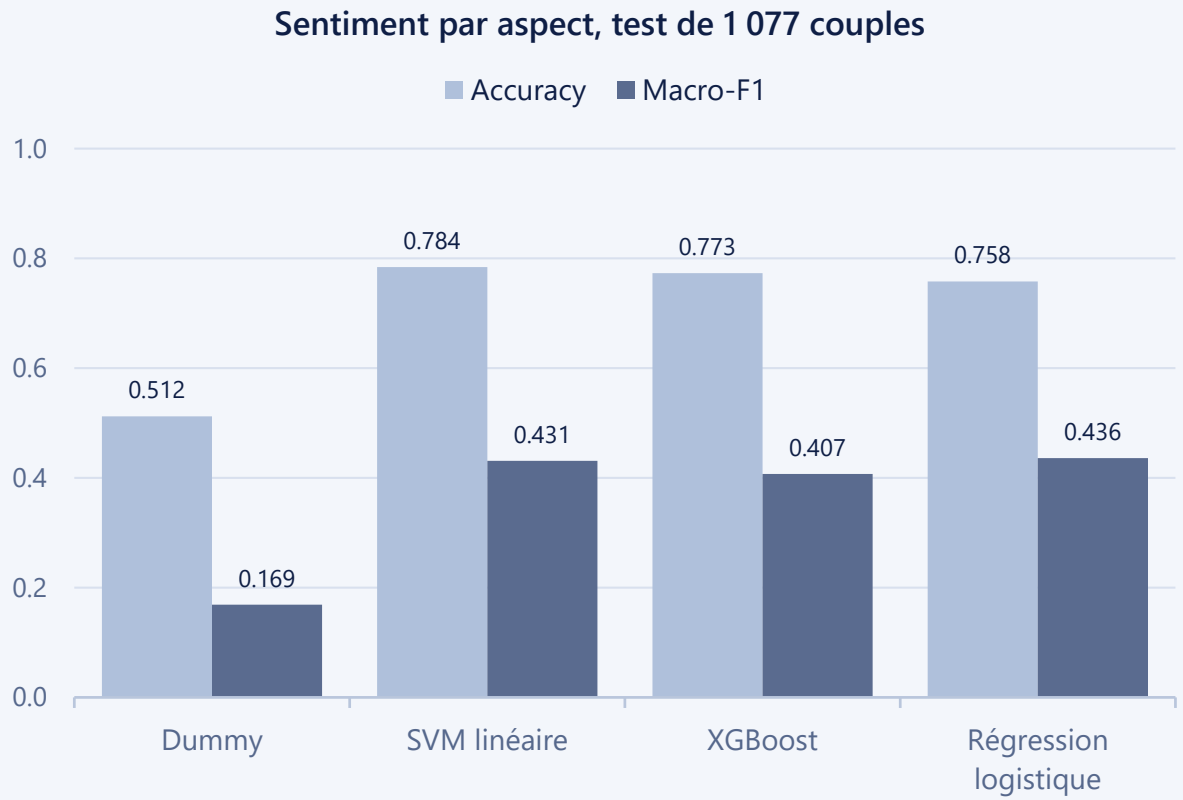
F1 = 0,439



Pronoms et mots vides : des associations de contexte à examiner

Les coefficients décrivent des associations apprises, pas des causes : ils orientent l'analyse des erreurs

Sentiment : les modèles classiques passent à côté de mixed et neutral



Matrice de confusion, régression logistique

Réel \ prédit	negative (571)	positive (429)	mixed (75)	neutral (2)
negative (551)	**455**	53	42	1
positive (454)	78	**352**	24	0
mixed (59)	30	19	**9**	1
neutral (13)	8	5	0	**0**

- mixed : **9/59** retrouvés, pour 75 prédictions
- mixed manqués : 30 prédits negative, 19 positive et 1 neutral
- neutral : **0/13** couple reconnu

L'optimisation n'apporte aucun gain : le Macro-F1 reste à 0,436, avec C = 1 retenu par validation croisée groupée par avis

04

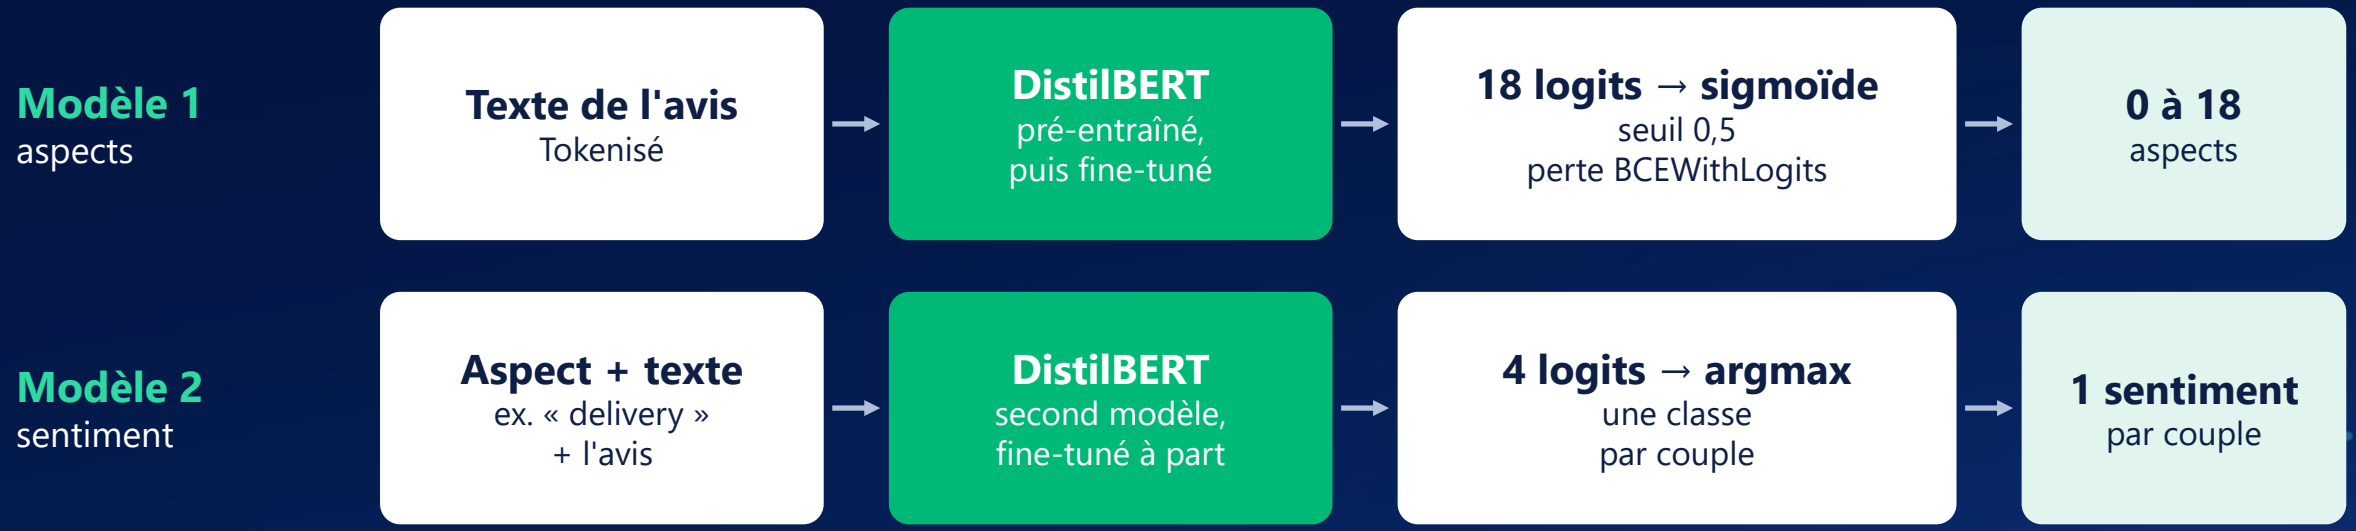
DistilBERT

Fine-tuning de deux modèles, un par tâche, sur CPU



DistilBERT lit l'avis en contexte : deux modèles fine-tunés, un par tâche

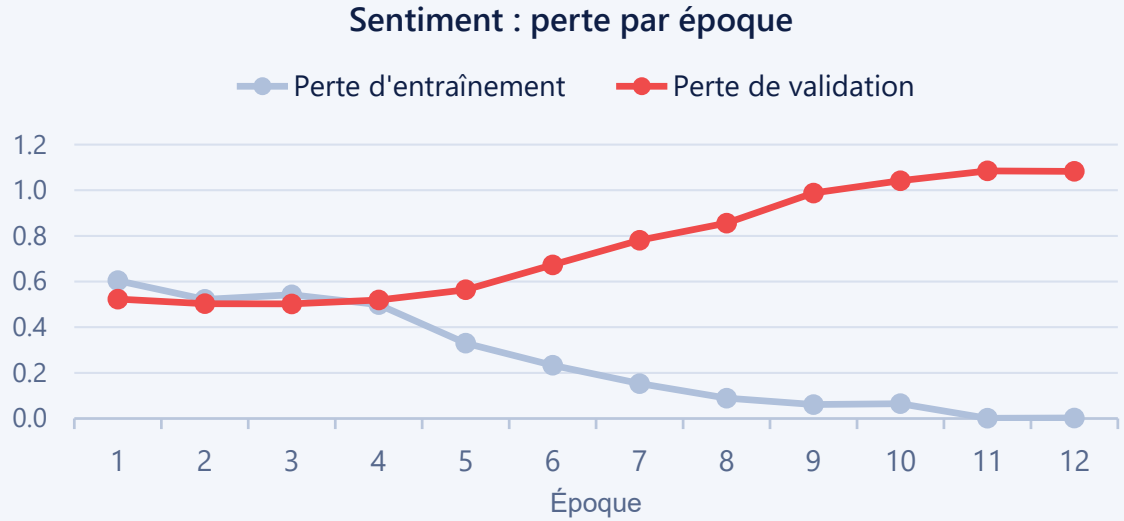
Pourquoi : TF-IDF compte des mots et des paires de mots ; l'attention relie chaque mot au reste de l'avis.

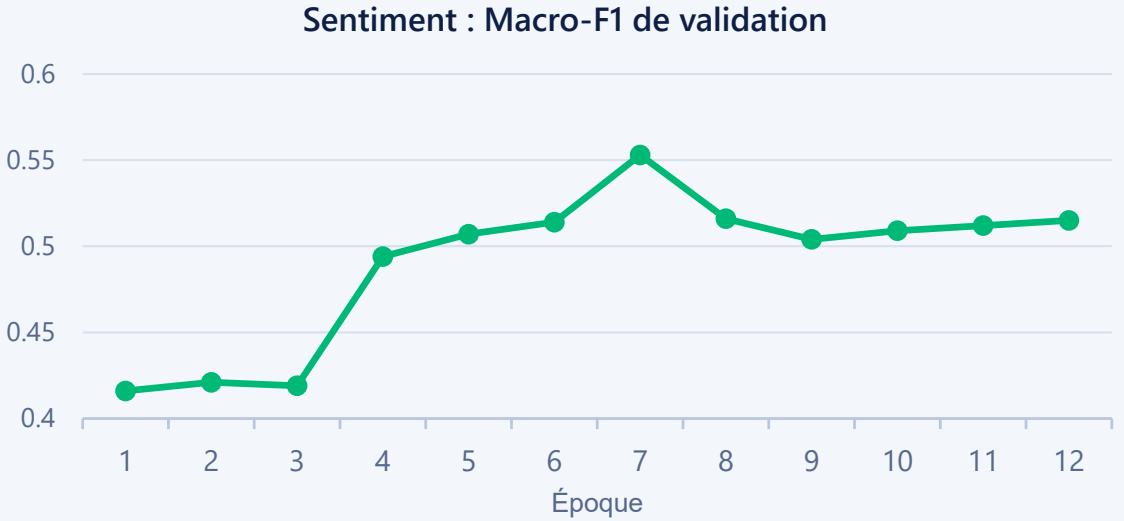


5×10^{-5}	8 / 16	0,01	128
taux d'apprentissage	batch train / évaluation	weight decay	tokens maximum par texte

distilbert-base-uncased : environ 40 % de paramètres en moins que BERT. Entraînement sur CPU ; un essai BERT-base a été arrêté après 2 époques.

Les époques sont choisies sur le Macro-F1 de validation, pas sur la perte





Aspects · 11 époques

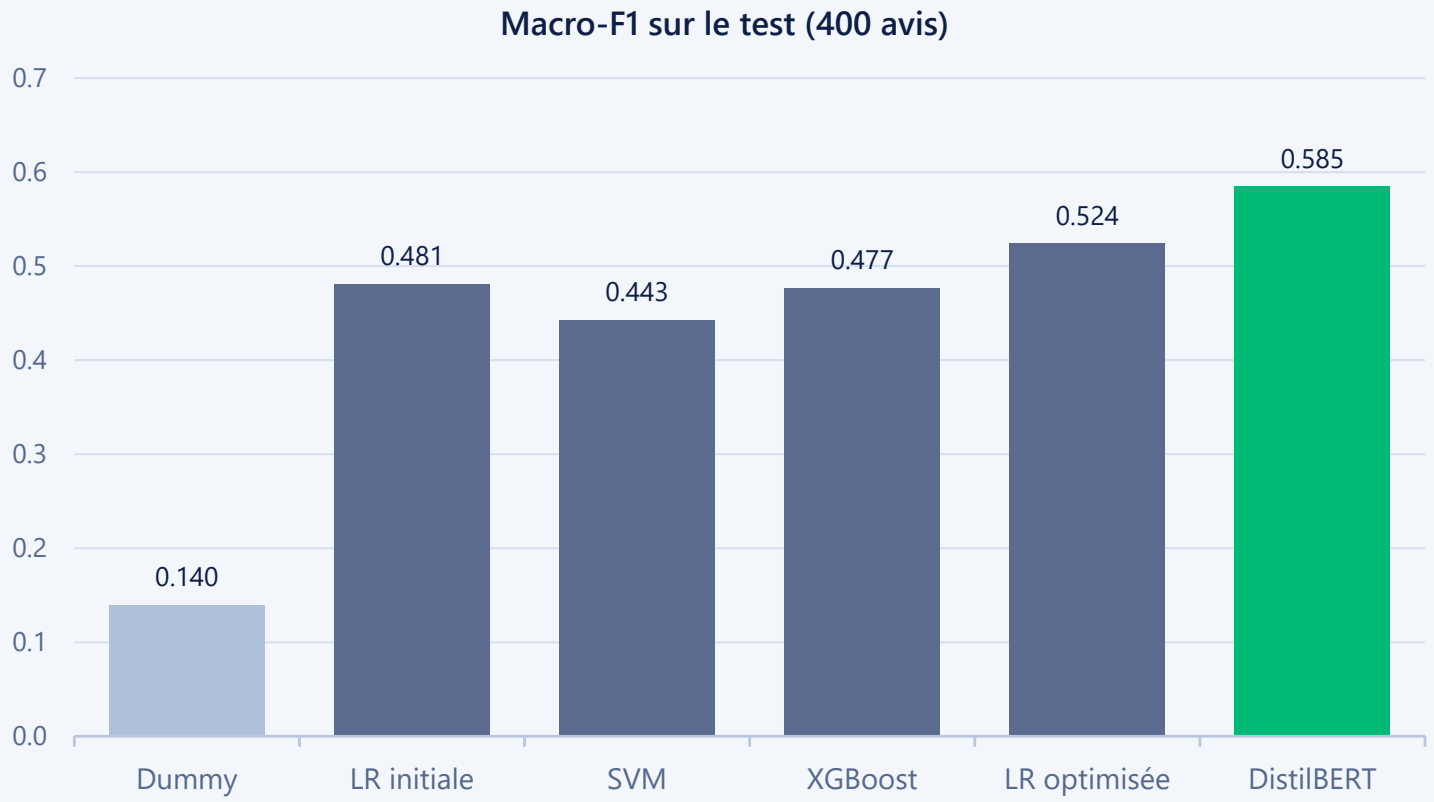
Validation 1 280 / 320 avis ; meilleur Macro-F1 de validation 0,372 à l'époque 11 ; réentraînement sur les 1 600 avis

Sentiment · 7 époques

Validation séparée par avis : 3 447 / 832 couples ; pic de Macro-F1 à 0,553 ; réentraînement sur les 4 279 couples

La perte de validation remonte dès l'époque 4, mais le Macro-F1 culmine à l'époque 7, retenue

Détection des aspects : DistilBERT dépasse tous les modèles classiques



0,585

Macro-F1
+0,061
vs LR optimisée (0,524)

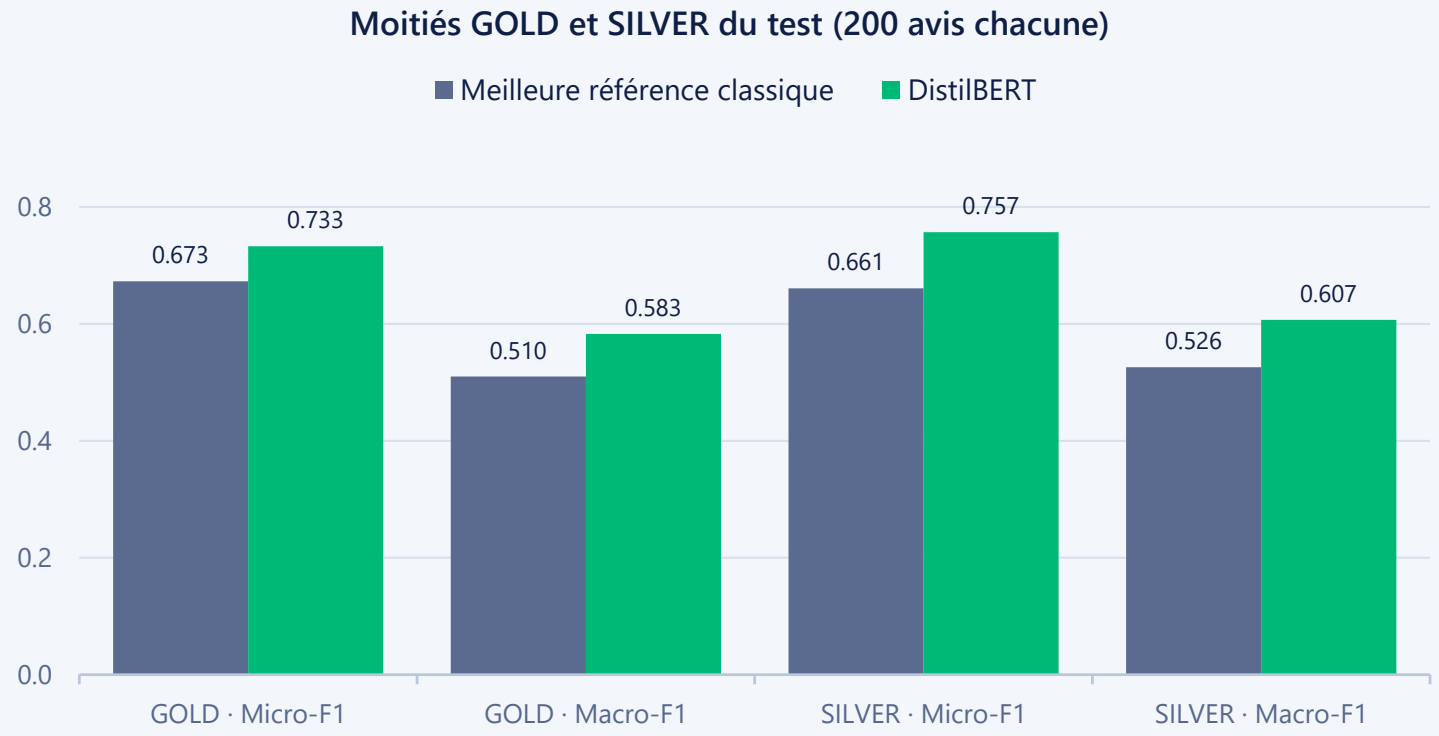
0,745

Micro-F1
+0,078
vs LR initiale (0,667)

Plus prudent
précision micro 0,800
rappel micro 0,697

DistilBERT améliore les deux métriques à la fois, là où l'optimisation de la LR en sacrifiait une

DistilBERT progresse aussi sur le GOLD vérifié manuellement



Références classiques : LR initiale pour le Micro-F1, LR optimisée pour le Macro-F1.

GOLD **+0,060 / +0,073**

Micro / Macro-F1 sur le GOLD vérifié et validé par l'annotateur

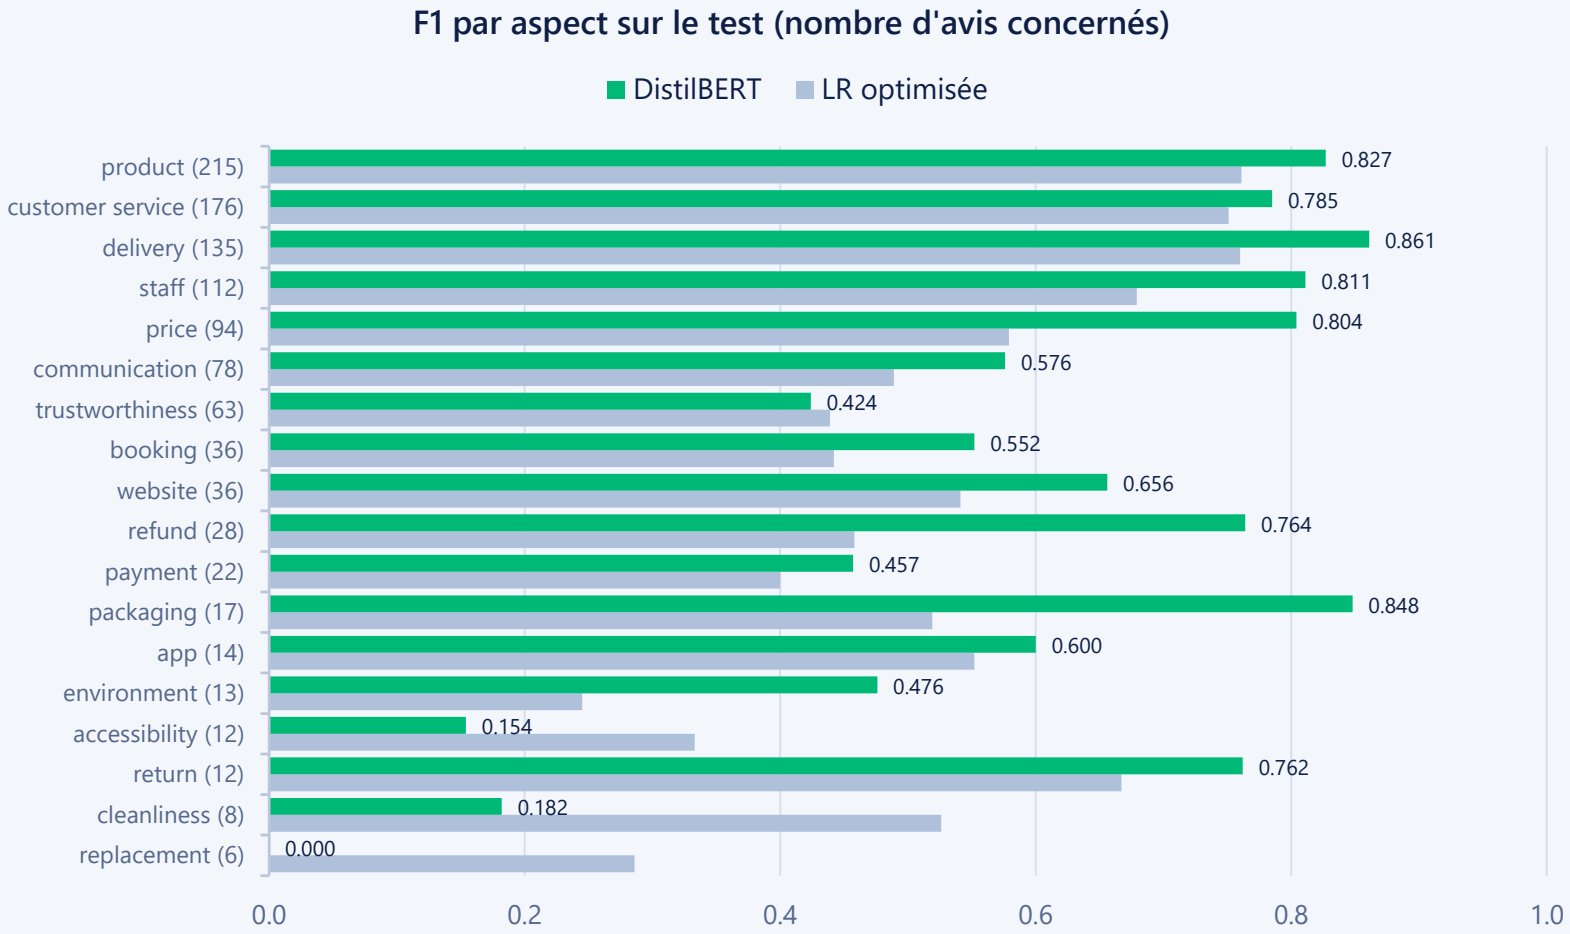
SILVER **+0,096 / +0,081**

Accord avec les labels produits par le LLM

Les deux moitiés diffèrent aussi par leurs textes et leurs aspects : leur écart ne s'attribue pas au seul LLM.

Sur GOLD : Macro-F1 de 0,510 pour la LR optimisée et 0,583 pour DistilBERT, soit +0,073

Face à la LR optimisée, DistilBERT progresse sur 14 des 18 aspects



Gains de F1 vs LR optimisée

- packaging +0,329
- refund +0,306
- environment +0,231
- price +0,225

Reculs et cas retrouvés

- cleanliness : 1 sur 8
- replacement : 0 sur 6
- accessibility : 1 sur 12
- trustworthiness : −0,015

Six aspects ont moins de 15 avis de test. Un seul cas peut faire varier leur F1.

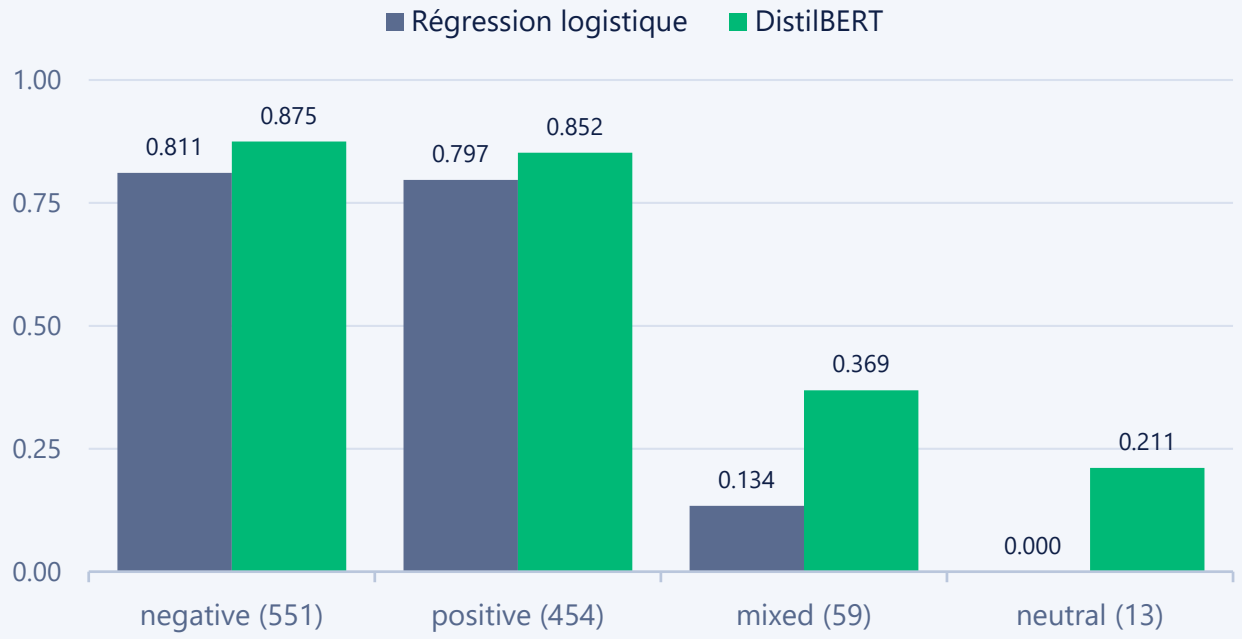
Sentiment : le gain le plus net porte sur mixed et neutral

0,829 — **Accuracy** **+4,5 pts** vs SVM (0,784)

0,577 — **Macro-F1** **+0,141** vs LR (0,436)

0,830 — **Weighted-F1** **+0,062** vs SVM (0,768)

F1 par sentiment sur le test (nombre de couples)



Matrice de confusion, DistilBERT

Réel \ prédit	negative	positive	mixed	neutral
negative	**491**	33	24	3
positive	54	**376**	23	1
mixed	17	18	**24**	0
neutral	9	2	0	**2**

- mixed : 24 couples sur 59 retrouvés, contre 9 pour la LR
- neutral : 2 sur 13, une classe encore fragile (57 exemples d'entraînement)
- negative et positive : F1 au-dessus de 0,85

893 couples bien classés sur 1 077

Un avis, deux aspects et des sentiments opposés

« The delivery was very late, but the customer service was excellent and very helpful. »

Aspect	Pipeline classique (TF-IDF + LR)	Pipeline DistilBERT	Attendu
customer service	✓ **positive**	✓ **positive**	positive
delivery	✗ **positive : sentiment faux**	✓ **negative**	negative
staff	✗ **positive : aspect en trop**	✓ **non détecté**	absent

Cette erreur illustre la difficulté à rattacher chaque appréciation à son aspect. Cet exemple ne permet pas d'isoler les mots responsables.

Une illustration sur un exemple : la chaîne complète n'a pas encore de score chiffré sur le test

05

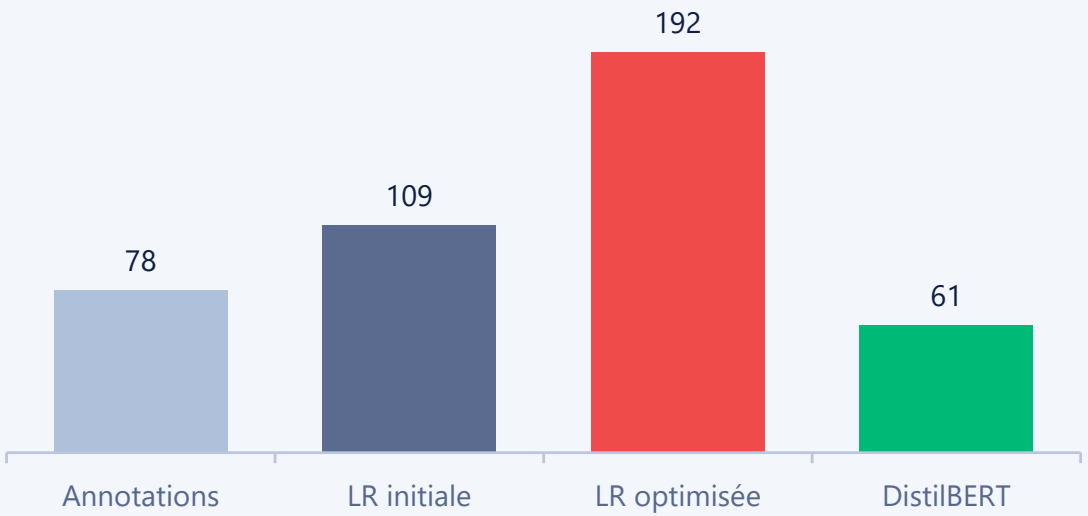
Analyse critique

Usage métier, limites et suites du projet



Pour un usage métier, la précision compte autant que le score global

Avis signalés pour communication (test, 400 avis)



DistilBERT : 61 avis signalés, pour 78 réellement concernés

Correctement repérés	Signalés à tort	Manqués
40	21	38

×2,46

Tableau de bord faussé

48 % des avis signalés par la LR optimisée pour communication, contre 19,5 % annotés (DistilBERT : 15,25 %).

Elle signale 192 avis, dont 126 à tort (66 corrects), pour 78 avis réellement concernés : elle surestime fortement le volume.

+0,006

Aspects rares très sensibles

LR optimisée : corriger un seul faux négatif sur replacement porterait son F1 de 0,286 à 0,400, soit environ +0,006 de Macro-F1 global.

Validations non directement comparables

LR : 0,487 pour choisir le seuil. DistilBERT : 0,372 pour choisir l'époque. Les procédures diffèrent. Ces scores ne mesurent pas un renversement du classement.

La robustesse des écarts reste à confirmer par un protocole commun et un bootstrap apparié par avis

Sept limites à lever avant un usage réel, et une piste pour chacune

	Limite	Constat	Prochaine étape
	Classes rares	accessibility 1/12, cleanliness 1/8, replacement 0/6 ; neutral : F1 0,211	Annoter plus de GOLD sur ces aspects, ainsi que sur mixed et neutral
	Précision et rappel	Rappel de DistilBERT : 0,513 sur communication, 0,333 sur trustworthiness	Seuil par aspect testé sur une validation indépendante, selon l'usage visé
	Annotations SILVER	75 % des avis du train et 50 % des avis du test sont SILVER ; leur qualité globale n'a pas été mesurée.	Relire un échantillon SILVER ; évaluer le sentiment séparément sur GOLD et SILVER
	Protocole	Choix du modèle de sentiment sur le test. TF-IDF appris avant les plis lors des recherches d'hyperparamètres.	Pipeline dans chaque pli, validation croisée avant sélection, nouveau test réservé
	Chaîne complète	Sentiment évalué avec les aspects annotés : pas de score de bout en bout	Mesurer aspects ajoutés, oubliés et sentiments faux, puis analyser sur GOLD
	Représentativité	Plafond de 20 avis par note et par entreprise ; avis UK, en anglais	Évaluer sur un flux d'avis réel, tiré sans plafond par note
	Calcul	CPU uniquement : 128 tokens, BERT-base arrêté après 2 époques	GPU pour tester la longueur maximale et la pondération de la perte

SYNTHÈSE

DistilBERT retenu : meilleurs résultats observés sur les deux tâches

0,745

Micro-F1 · aspects

+0,078 vs LR initiale

0,585

Macro-F1 · aspects

+0,061 vs LR optimisée

0,829

Accuracy · sentiment

+4,5 pts vs SVM

0,577

Macro-F1 · sentiment

+0,141 vs LR

1

Un corpus riche, mais biaisé

123 181 avis Hugging Face, plafonnés à 20 avis par note et par entreprise

2

2 000 avis annotés sur 18 aspects

600 avis GOLD vérifiés, 1 400 avis SILVER produits par un LLM ; 1 994 avec au moins un aspect et 5 356 couples annotés

3

DistilBERT dépasse les modèles classiques

Hausse sur les quatre métriques ; +0,073 sur GOLD (aspects)

4

Des limites avant un usage réel

Classes rares, qualité du SILVER, chaîne complète non mesurée

Merci de votre attention. Questions ?

ANNEXE

Scores des six configurations sur le même test, et sources

	Aspects · test de 400 avis				Sentiment · 1 077 couples		
Modèle	**Micro-F1**	**Macro-F1**	**Macro GOLD**	**Macro SILVER**	**Accuracy**	**Macro-F1**	**Weighted-F1**
Dummy	0,307	0,140	0,145	0,132	0,512	0,169	0,346
LR initiale	0,667	0,481	0,504	0,464	0,758	0,436	0,758
SVM linéaire	0,648	0,443	0,468	0,425	0,784	0,431	0,768
XGBoost	0,648	0,477	0,509	0,439	0,773	0,407	0,750
LR optimisée	0,615	0,524	0,510	0,526	0,758	0,436	0,758
DistilBERT	**0,745**	**0,585**	**0,583**	**0,607**	**0,829**	**0,577**	**0,830**

Dummy : stratifié pour les aspects, majoritaire (toujours negative) pour le sentiment. LR optimisée, sentiment : C = 1 conservé, scores identiques à la LR initiale.

Sources

Données : Kerassy trustpilot-reviews-123k (Hugging Face) · Trustpilot Reviews Dataset (Kaggle) · Trustpilot, Transparency Report 2022 Transparency Report.

Méthodes et outils : Victor Sanh, Lysandre Debut, Julien Chaumond et Thomas Wolf, 2019, DistilBERT. · Transformers (Hugging Face) · scikit-learn, Transformers et PyTorch.

ANNEXE

Scores détaillés des 18 aspects sur les 400 avis de test

Aspect	n	F1 LR	F1 DistilBERT
product	215	0,761	**0,827**
customer service	176	0,751	**0,785**
delivery	135	0,760	**0,861**
staff	112	0,679	**0,811**
price	94	0,579	**0,804**
communication	78	0,489	**0,576**
trustworthiness	63	0,439	**0,424**
booking	36	0,442	**0,552**
website	36	0,541	**0,656**

Aspect	n	F1 LR	F1 DistilBERT
refund	28	0,458	**0,764**
payment	22	0,400	**0,457**
packaging	17	0,519	**0,848**
app	14	0,552	**0,600**
environment	13	0,245	**0,476**
accessibility	12	0,333	**0,154**
return	12	0,667	**0,762**
cleanliness	8	0,526	**0,182**
replacement	6	0,286	**0,000**

n : nombre d'avis annotés avec l'aspect. LR : configuration optimisée. En vert, DistilBERT fait mieux ; en rouge, il recule. Les très petits supports rendent le F1 instable.